

Tarea Minería de Datos

‘Test de Evaluación’

La entrega se realizará en la plantilla excel adjunta indicando, para cada pregunta, la única respuesta correcta.

Test_Minería_NombreApellido.xlsx

Todas las preguntas valen un punto y las respuestas incorrectas penalizan medio punto.

Pregunta 1

¿Cuál de los siguientes NO es un requisito previo recomendado para aplicar el PCA?

- a) Estandarización de las variables.*
- b) Ausencia de correlación entre las variables originales.*
- c) Manejo de valores atípicos.*
- d) Tratamiento de datos perdidos.*

Pregunta 2

En el PCA, ¿qué representa un autovalor (valor propio) alto?

- a) Que la componente asociada explica poca varianza.*
- b) Que la componente asociada explica mucha varianza.*
- c) Que la componente está correlacionada negativamente con todas las variables.*
- d) Que la componente es redundante y debe eliminarse.*

Pregunta 3

¿Qué matriz se utiliza generalmente cuando las variables originales no están en la misma escala?

- a) Matriz de covarianzas.*
- b) Matriz de identidad.*
- c) Matriz de correlaciones.*
- d) Matriz de distancias.*

El conjunto de datos 'penguins' contiene la siguiente información sobre diferentes especies de pingüinos:

- species: Es la especie de pingüino. Hay tres especies en el conjunto de datos: 'Adelie', 'Chinstrap' y 'Gentoo'.

- *island*: Representa la isla donde se recopilaron los datos. Las islas son 'Biscoe', 'Dream' y 'Torgersen'.
- *bill length mm*: Longitud del pico en milímetros.
- *bill depth mm*: Profundidad del pico en milímetros.
- *flipper length mm*: Longitud de la aleta en milímetros.
- *body mass g*: Masa corporal del pingüino en gramos.
- *sex*: Género del pingüino, con las categorías 'Male' (macho), 'Female' (hembra).

Con el objetivo de reducir el número de variables numéricas y explorar relaciones entre las características físicas de los pingüinos se ha realizado un análisis PCA sobre el conjunto de datos de las variables numéricas.

Pregunta 4

Después de aplicar el PCA, obtener los autovalores asociados a las 4 componentes principales. ¿Cuál es la varianza explicada por la segunda componente principal (PC2) en porcentaje?

- a) 19.45%
- b) 68.84%
- c) 29.87%
- d) 9.25%

Pregunta 5

¿Cuántas componentes principales se necesitan para explicar al menos el 90% de la variabilidad total de los datos?

- a) 1 componente
- b) 2 componentes
- c) 3 componentes
- d) 4 componentes

Pregunta 6

En la siguiente tabla se muestra la matriz de transformación W . Indica cuál de las siguientes expresiones es correcta:

Index	Autovector 1	Autovector 2
bill_length_mm_z	0.453753	0.600195
bill_depth_mm_z	-0.399047	0.79617
flipper_length_mm_z	0.576825	0.00578817
body_mass_g_z	0.549675	0.0764637

- a) $CP1 = 0.6Bill_length_mm_z + 0.796Bill_depth_mm_z + 0.005Flipper_length_mm_z + 0.076Body_mass_g_z$
- b) $CP1 = 0.453Bill_length_mm_z + 0.6Bill_depth_mm_z - 0.399Flipper_length_mm_z + 0.796Body_mass_g_z$
- c) $CP2 = 0.453Bill_length_mm_z - 0.399Bill_depth_mm_z + 0.576Flipper_length_mm_z + 0.549Body_mass_g_z$
- d) $CP2 = 0.6Bill_length_mm_z + 0.796Bill_depth_mm_z + 0.005Flipper_length_mm_z + 0.076Body_mass_g_z$

Pregunta 7

Tras realizar un PCA sobre las variables del conjunto penguins, obtienes las correlaciones entre las variables estandarizadas y las dos primeras componentes principales.

¿Cuál de las siguientes variables tiene la correlación más fuerte con la primera componente principal (PC1)?

- a) *bill_length_mm_z*
- b) *bill_depth_mm_z*
- c) *flipper_length_mm_z*
- d) *body_mass_g_z*

Pregunta 8

Según los resultados del PCA, ¿qué variable contribuye más a la segunda componente principal (PC2) en términos de correlación absoluta?

- a) *bill_length_mm_z*
- b) *bill_depth_mm_z*
- c) *flipper_length_mm_z*
- d) *body_mass_g_z*


Pregunta 9

Para la variable *bill_depth_mm_z*, ¿qué porcentaje aproximado de su varianza es explicado por PC2?

- a) 28.0%
- b) 43.7%
- c) 49.3%
- d) 70.2%

Pregunta 10

Observa los siguientes gráficos obtenidos del PCA (*plot_corr_cos* y *nube de puntos sobre las dos primeras componentes*) aplicado al conjunto de datos penguins.



Teniendo en cuenta la interpretación de las componentes, ¿cuál de las siguientes descripciones es la más probable para el pingüino 246 (arriba a la derecha)?

- Tiene valores altos en longitud de aleta y masa corporal, y valores bajos en profundidad del pico.
- Tiene valores por debajo de la media en longitud de aleta y masa corporal, y valores por encima de la media en profundidad del pico.
- Tiene valores por encima de la media en longitud de aleta y masa corporal, y valores por debajo de la media en profundidad del pico.
- Tiene valores cercanos a la media en todas las variables.

Tras explorar las características físicas de los pingüinos mediante el Análisis de Componentes Principales (ACP), ahora nos centraremos en evaluar la estructura de los grupos o clústeres existentes en el conjunto de datos a partir de las variables numéricas.

Pregunta 11

En el clustering jerárquico, ¿qué representa un dendrograma?

- La evolución de los centroides en cada iteración.
- La estructura de fusión o división de grupos en forma de árbol.
- La distribución de las variables dentro de cada cluster.
- La matriz de distancias entre todas las observaciones.

Pregunta 12

En el método del codo para determinar el número óptimo de clusters, ¿qué se representa en el eje Y?

- a) El coeficiente de silueta promedio.
- b) La suma de cuadrados dentro de los clusters.
- c) La distancia entre centroides.
- d) El número de observaciones por cluster.

Pregunta 13

¿Qué solución de Clustering es mejor?

- a) Solución con el mayor número de grupos.
- b) Solución con mayor variabilidad interna y menor silueta.
- c) Solución con menor silueta y variabilidad interna.
- d) Solución con mayor silueta y menor variabilidad interna.

Pregunta 14

Observa los siguientes dendrogramas y selecciona una de las 4 opciones.




Ilustración 1 Dendrograma 1




Ilustración 2 Dendrograma 2




Ilustración 3 Dendrograma 3

- a) El primer dendrograma es el correspondiente a la base de datos de pingüinos.
- b) El segundo dendrograma es el correspondiente a la base de datos de pingüinos.
- c) El tercer dendrograma es el correspondiente a la base de datos de pingüinos.
- d) Ninguna es correcta.

Pregunta 15

Observa los siguientes gráficos “de codo” y selecciona una de las 4 opciones.





Ilustración 4 Codo 1




Ilustración 5 Codo 2

Ilustración 6 Codo 3

- a) El primer gráfico es el correspondiente a la base de datos de pingüinos.
- b) El segundo gráfico es el correspondiente a la base de datos de pingüinos.
- c) El tercer gráfico es el correspondiente a la base de datos de pingüinos.
- d) Ninguna es correcta.

Pregunta 16

Observa los siguientes gráficos “de silueta” y selecciona una de las 4 opciones.




Ilustración 7 Gráfico 1




Ilustración 8 Gráfico 2





Ilustración 9 Gráfico 3

- El primer gráfico es el correspondiente a la base de datos de pingüinos.*
- El segundo gráfico es el correspondiente a la base de datos de pingüinos.*
- El tercer gráfico es el correspondiente a la base de datos de pingüinos.*
- Ninguna es correcta.*

Pregunta 17

En los siguientes gráficos se muestran las nubes de puntos de los pingüinos sobre las dos primeras componentes principales, los colores representan a que clúster pertenecen, ya sea en un análisis con dos o tres clúster respectivamente. Selecciona una de las 4 opciones.



- Es más acertado elegir tres clúster porque originariamente existen tres especies de pingüinos.*
- Es más acertado elegir tres clúster porque originariamente los pingüinos proceden de tres islas diferentes.*
- Es más acertado elegir dos clúster porque las fronteras entre los grupos son más claras.*
- Las respuestas a) y b) son correctas.*

