



‘Minería de datos y modelización predictiva’

Pablo Blas Hernández

1. Introducción

El objetivo principal de esta práctica es analizar la influencia de factores demográficos, socioeconómicos y territoriales en los resultados electorales de los municipios de España. El estudio se centra en el voto a partidos de derecha (PP y Ciudadanos) y se aborda desde una doble perspectiva analítica mediante dos variables objetivo:

- "Dcha_Pct" (variable continua): Porcentaje de votos a partidos de derecha (PP y Ciudadanos). Su naturaleza continua permite utilizar un modelo de regresión lineal para explorar cómo las variables explicativas influyen en este porcentaje.
- "Derecha" (variable dicotómica): Toma el valor 1 si la suma de los votos de derecha es superior a la de izquierda y otros y, 0, en otro caso. Al ser una variable binaria, se empleará un modelo de regresión logística para identificar qué variables predictoras aumentan o disminuyen la probabilidad de que un municipio tenga una mayoría de votos de derecha.

El conjunto de variables explicativas incluye indicadores demográficos como población, densidad y crecimiento poblacional; variables económicas relacionadas con la actividad predominante, los servicios y el comercio; variables habitacionales asociadas a las condiciones de vida; y variables territoriales vinculadas a la estructura productiva y al tamaño del municipio. Estas variables permiten capturar distintas dimensiones estructurales que pueden estar relacionadas con las preferencias políticas locales. Asimismo, siguiendo las especificaciones de la práctica, se excluirán del conjunto de variables explicativas el resto de las variables objetivo no seleccionadas (la abstención o el voto a otros bloques) para evitar sesgos y garantizar la independencia del análisis.

La metodología del estudio comprende un análisis exploratorio de datos (EDA) para detectar patrones, valores atípicos y problemas de calidad de los datos, seguido de un proceso de limpieza, tratamiento de valores atípicos e imputación de datos faltantes. Posteriormente, se construyen los modelos de regresión lineal y logística aplicando técnicas de selección de variables para identificar los predictores más relevantes. Finalmente, se evalúa el desempeño de los modelos y se interpretan los resultados para extraer conclusiones sustantivas.

En conjunto, este trabajo no solo busca predecir los resultados electorales municipales, sino también aportar una interpretación estadística y empírica de los factores socioeconómicos que subyacen al comportamiento electoral en España.

2. Importación y Análisis inicial

El primer paso en cualquier proyecto de minería de datos es importar las librerías que va a requerir nuestro proyecto. En este caso, importamos todo el contenido del archivo `FuncionesMineria.py`, de la siguiente manera: `from FuncionesMineria import *`. El conjunto de datos que utilizaremos es "DatosEleccionesEspaña.xlsx", que se importó utilizando la función `pd.read_excel()` de `pandas`. A continuación, eliminamos las variables objetivo que no forman parte del estudio y, además, se elimina la variable

‘CodigoProvincia’ por no aportar información relevante, y se establece la variable ‘Name’ como índice.

```
df = pd.read_excel('DatosEleccionesEspaña.xlsx')

# Eliminamos el resto de variables objetivo y que no aportan info
df.drop(['Izda_Pct', 'Izquierda', 'Otros_Pct', 'AbstentionPtge', 'AbstencionAlta', 'CodigoProvincia', 'Unnamed: 41'], axis=1, inplace=True)

df = df.set_index(df['Name']).drop('Name', axis = 1)
```

El siguiente paso es verificar los tipos de datos asignados mediante `df.dtypes`, identificando la siguiente inconsistencia: ‘Derecha’ (variable binaria) se importa como numérica (int64), pero debe tratarse como categoría nominal, por lo que se corrige convirtiéndola a tipo string.

Variable	dtype
CCAA	object
Population	int64
TotalCensus	int64
Dcha_Pct	float64
Derecha	int64
Age_0-4_Ptge	float64
Age_under19_Ptge	float64
Age_19_65_pct	float64
Age_over65_pct	float64
WomanPopulationPtge	float64
ForeignersPtge	float64
SameComAutonPtge	float64
SameComAutonDiffProvPtge	float64
DifComAutonPtge	float64
UnemployLess25_Ptge	float64
Unemploy25_40_Ptge	float64
UnemployMore40_Ptge	float64
AgricultureUnemploymentPtge	float64
IndustryUnemploymentPtge	float64
ConstructionUnemploymentPtge	float64
ServicesUnemploymentPtge	float64
totalEmpresas	float64
Industria	float64
Construccion	float64
ComercioHosteleria	float64
Servicios	float64
ActividadPpal	object
inmuebles	float64
Pob2010	float64
SUPERFICIE	float64
Densidad	object
PobChange_pct	float64
PersonasInmueble	float64
Explotaciones	int64
dtype:	object

```
# Convertimos la variable 'Derecha' a categoría
numERICA_a_categoria = ['Derecha']

for var in numERICA_a_categoria :
    df[var] = df[var].astype(str)
```

3. Análisis descriptivo

El análisis descriptivo se dividirá en variables numéricas y categóricas.

3.1. Numéricas

```
numERICas = df.select_dtypes(include=['number']).columns

estadisticos_var_num = df.describe().T

# Calculamos medidas extra
for num in numERICas:
    estadisticos_var_num.loc[num, "Asimetria"] = df[num].skew()
    estadisticos_var_num.loc[num, "Kurtosis"] = df[num].kurtosis()
    estadisticos_var_num.loc[num, "Rango"] = np.ptp(df[num].dropna().values)

estadisticos_var_num
```

	count	mean	std	min	25%	50%	75%	max	Asimetria	Kurtosis	Rango
Population	8117.0	5722.344709	46204.175926	5.0000	166.0000	548.0000	2427.0000	3141991.0000	46.040721	2820.326827	3.141986e+06
TotalCensus	8117.0	4247.863989	34423.439346	5.0000	140.0000	447.0000	1843.0000	2363829.0000	46.544648	2893.452945	2.363824e+06
Dcha_Pct	8117.0	48.912166	19.946471	0.0000	38.6900	51.579	62.1870	100.0000	-0.467616	-0.175615	1.000000e+02
Age_0_4_Ptge	8117.0	3.018274	2.052625	0.0000	1.3890	2.975	4.5330	13.245	0.343639	-0.206688	1.324500e+01
Age_under19_Ptge	8117.0	13.564087	6.777445	0.0000	8.3340	13.881	19.0550	33.696	-0.104763	-0.792250	3.369600e+01
Age_19_65_pct	8117.0	57.370592	6.818637	23.4590	53.8450	58.655	61.8180	100.002	-0.814264	2.155839	7.654300e+01
Age_over65_pct	8117.0	29.065321	11.767040	-18.0520	19.8270	27.559	36.9110	76.472	0.584708	0.102323	9.452400e+01
WomanPopulationPtge	8117.0	47.302297	4.362347	11.7650	45.7250	48.485	50.0000	72.683	-1.671102	5.800629	6.091800e+01
ForeignersPtge	8117.0	5.618322	7.348700	-8.9600	1.0600	3.590	8.1800	71.470	2.498262	11.356789	8.043000e+01
SameComAutonPtge	8117.0	81.633460	12.287323	0.0000	75.8060	84.493	90.4620	127.156	-1.522758	3.479538	1.271560e+02
SameComAutonDiffProvPtge	8117.0	4.337637	6.394942	0.0000	0.6760	2.190	5.2770	67.308	3.286828	14.560136	6.730800e+01
DiffComAutonPtge	8117.0	10.727261	8.847631	0.0000	4.9330	8.269	13.8910	100.0000	2.425991	9.663965	1.000000e+02
UnemployLess25_Ptge	8117.0	7.320241	9.408801	0.0000	0.0000	5.882	10.4670	100.0000	4.150962	31.664819	1.000000e+02
Unemploy25_40_Ptge	8117.0	37.001267	20.319055	0.0000	28.5710	39.927	46.6670	100.0000	0.213481	1.412091	1.000000e+02
UnemployMore40_Ptge	8117.0	55.678492	22.087672	0.0000	44.1710	52.0000	64.5830	100.0000	0.259701	0.705886	1.000000e+02
AgricultureUnemploymentPtge	8117.0	8.402873	12.959440	0.0000	0.0000	3.497	11.7410	100.0000	3.228916	15.572833	1.000000e+02
IndustryUnemploymentPtge	8117.0	10.009590	12.529462	0.0000	0.0000	7.143	14.2860	100.0000	3.089440	16.047235	1.000000e+02
ConstructionUnemploymentPtge	8117.0	10.838410	13.282677	0.0000	0.0000	8.333	14.2860	100.0000	3.093595	14.620223	1.000000e+02
ServicesUnemploymentPtge	8117.0	58.646833	24.261857	0.0000	50.0000	62.0000	72.1310	100.0000	-0.805605	0.800001	1.000000e+02
totalEmpresas	8112.0	397.701430	4219.492916	0.0000	7.0000	30.0000	147.0000	299397.0000	53.713554	3475.479731	2.993970e+05
Industria	7929.0	23.405347	158.628346	0.0000	0.0000	0.0000	14.0000	10521.0000	44.270924	2643.854715	1.052100e+04
Construccion	7978.0	48.811482	421.895011	0.0000	0.0000	0.0000	25.0000	30343.0000	52.577422	3506.443836	3.034300e+04
ComercioTTEHosteleria	8108.0	146.208806	1232.713016	0.0000	0.0000	0.0000	65.0000	80856.0000	45.459601	2652.634653	8.085600e+04
Servicios	8055.0	171.849783	2447.041982	0.0000	0.0000	0.0000	40.0000	177677.0000	57.502990	3833.616264	1.776770e+05
inmuebles	7979.0	3240.038225	24314.681445	6.0000	180.0000	485.0000	1586.5000	1615548.0000	44.561466	2646.689444	1.615542e+06
Pob2010	8110.0	5777.929840	47527.883258	5.0000	177.2500	581.5000	2482.7500	3273049.0000	47.200624	2944.830055	3.273044e+06
SUPERFICIE	8109.0	6215.296238	9218.604158	2.5784	1839.2392	3488.552	6894.5272	175022.910	6.073326	62.335015	1.750203e+05
PobChange_pct	8110.0	-4.900726	10.382355	-52.2700	-10.4000	-4.965	0.0900	138.460	1.506444	15.112052	1.907300e+02
PersonasInmueble	7979.0	1.295565	0.565993	0.1100	0.8500	1.250	1.7300	3.330	0.259748	-0.645897	3.220000e+00
Explotaciones	8117.0	2447.806456	15064.545054	1.0000	22.0000	52.0000	137.0000	99999.0000	6.321265	37.977123	9.999800e+04

Variables demográficas:

- La población media por municipio es de 5722 habitantes, pero con una gran dispersión (DE ± 46204). Esto refleja la predominancia de municipios pequeños (mediana = 548 hab.) frente a grandes ciudades como Madrid (3.14M hab.), lo que explica la asimetría extrema (46.04).
- El 29.06% de la población media es mayor de 65 años ('Age_over65_pct'), pero se detectaron valores imposibles (-18.05%), lo que sugiere errores en los datos.
- 'Age_19_65_pct' registra un valor máximo ligeramente superior al 100%, un valor erróneo, pero que puede haber sido fruto de redondeo decimal, ya que es posible que un municipio, como un pueblo de zona rural con pocos habitantes, cuente solo con habitantes adultos de entre 19 y 65 años.
- 'SameComAutonPtge' registra un valor máximo del 127%, esto es totalmente erróneo.
- 'ForeignersPtge' al igual que cómo hemos mencionado previamente con 'Age_over65_pct' incluye valores negativos (-8.96%), claramente erróneos.

Variables políticas:

- 'Dcha_Pct' muestra una media del 48.91% (DE ± 19.95), con distribución casi simétrica (asimetría -0.47). Sin embargo, el rango completo (0-100) indica municipios con dominancia absoluta de un bloque político.

Variables económicas:

- Servicios domina el desempleo (58.65% del desempleo registrado), pero con alta variabilidad (DE ± 24.26).

- El número medio de empresas por municipio es 398, pero el 75% tiene menos de 147, frente a valores extremos como 299,397 en grandes ciudades (asimetría 53.71).
- Explotaciones tiene un valor máximo de 99.999, que codifica datos faltantes.

Variables habitacionales:

- ‘PersonasInmueble’, que tiene una media de 1,29 y un mínimo de 0,11, parece indicar viviendas vacías o segundas residencias

3.2. Categóricas

```

categoricas = df.select_dtypes(include='object').columns

estadisticos_var_cat = {}

for categoria in categoricas:
    if categoria in df.columns:
        counts = df[categoria].value_counts()
        resultado = pd.DataFrame({
            'n': counts,
            '%': (counts / counts.sum() * 100).round(2).astype(str) + '%'
        })
        estadisticos_var_cat[categoria] = resultado

tabla_final = pd.concat(estadisticos_var_cat, axis=0)

tabla_final.index.names = ['Variable', 'Categoría']

tabla_final

```

Variable	Categoría	n	%
CCAA	CastillaLeón	2248	27.69%
	Cataluña	947	11.67%
	CastillaMancha	919	11.32%
	Andalucía	773	9.52%
	Aragón	731	9.01%
	ComValenciana	542	6.68%
	Extremadura	387	4.77%
	Galicia	314	3.87%
	Navarra	272	3.35%
	PaísVasco	251	3.09%
	Madrid	179	2.21%
	Rioja	174	2.14%
	Cantabria	102	1.26%
Derecha	Canarias	88	1.08%
	Asturias	78	0.96%
	Baleares	67	0.83%
	Murcia	45	0.55%
	1	5041	62.1%
	0	3076	37.9%
ActividadPpal	Otro	4932	60.76%
	ComercTTEHosteleria	2538	31.27%
	Servicios	620	7.64%
	Construccion	14	0.17%
Densidad	Industria	13	0.16%
	MuyBaja	6416	79.04%
	Baja	1053	12.97%
	Alta	556	6.85%
	?	92	1.13%

En la variable ‘ActividadPpal’ hay categorías con poca representación como ‘Construcción’ e ‘Industria’ (<0.2% cada una). Estas deberían ser agrupadas para que tengan mayor representación.

Existen valores faltantes en la variable ‘Densidad’, que están representados como “?”. Estos valores deberán ser tratados posteriormente.

Castilla y León (27.69%), Cataluña (11.67%) y Castilla La Mancha (11.32%) son las comunidades autónomas con más representación. Asturias, Baleares y Murcia son las CCAA que tienen menos representación (<1% cada una). Estos resultados son esperados debido al número de municipios de cada CCAA, ya que las siguientes con más representación son Andalucía y Aragón. Hay muchas CCAA que no cuentan con una representación adecuada, sin embargo, agruparlas sin un estudio previo, podría derivar en

añadir subjetividad al modelo, ya que puede que no compartan características comunes, incluso “Data Leakage” si agrupamos en base a su predisposición de voto a la derecha (variable objetivo), lo que provocaría forzar al modelo al éxito y perder poder explicativo.

4. Corrección de los errores detectados

Los principales problemas identificados en el análisis exploratorio se han corregido mediante las siguientes acciones:

Agrupaciones de las categorías ‘Construcción’ e ‘Industria’ de la variable ‘ActividadPpal’ a ‘Otro’:

```
df['ActividadPpal'] = df['ActividadPpal'].replace({'Construccion': 'Otro', 'Industria': 'Otro'})
```

Tratamiento de los valores “?” en la variable ‘Densidad’, que son reemplazados por NaN. El mismo proceso se repite en la variable ‘Explotaciones’ con los valores “99999”.

```
df['Densidad'] = df['Densidad'].replace('?', np.nan)
df['Explotaciones'] = df['Explotaciones'].replace(99999, np.nan)
```

Se eliminan los porcentajes negativos de las variables ‘Age_over65_pct’ y ‘ForeignersPtge’, y los que superan el 100% de ‘SameComAutonPtge’, ya que son erróneos. Para la población mayor a 65 años y la población extranjera, en todo caso, su mínimo será 0%, pero no negativo. Para la población que reside en la misma CCAA de la que nacieron, en todo caso, su máximo será 100%, pero no mayor a este.

```
df['Age_over65_pct'] = [x if 0 <= x <= 100 else np.nan for x in df['Age_over65_pct']]
df['ForeignersPtge'] = [x if 0 <= x <= 100 else np.nan for x in df['ForeignersPtge']]
df['SameComAutonPtge'] = [x if 0 <= x <= 100 else np.nan for x in df['SameComAutonPtge']]
```

Se detectó una redundancia estructural en las variables de edad: la variable ‘Age_under19_Ptge’ incluía el subconjunto ‘Age_0-4_Ptge’, lo que generaba multicolinealidad perfecta y hacía que la suma total de porcentajes superase el 100%. En lugar de eliminar información, se opta por crear una nueva variable ‘Age_5_18_Ptge’ obtenida mediante la resta del porcentaje de 0-4 años (‘Age_0-4_Ptge’) al del grupo de menores de 19 (‘Age_under19_Ptge’). De esta forma, descomponemos la población joven en dos segmentos disjuntos, y eliminamos la variable original ‘Age_under19_Ptge’. Esto mejora la interpretabilidad del modelo y corrige la consistencia matemática de los datos. Además, se elimina la variable ‘Age_19_65_pct’ ya que podemos obtener sus datos a partir de las otras variables de edad, y la tomaremos como grupo referencia (‘Age_19_65_pct’ = 100 - ‘Age_0-4_Ptge’ - ‘Age_5_18_Ptge’ - ‘Age_over65_pct’):

```
# (Under19 ya incluye a 0-4, así que no lo sumamos doble)
df['check_sum'] = df['Age_under19_Ptge'] + df['Age_19_65_pct'] + df['Age_over65_pct']

# Opcional: Filtramos solo errores reales muy graves (ej: suma > 101% por error de redondeo).
df = df[(df['check_sum'] >= 99.0) & (df['check_sum'] <= 101.0)]

# Creamos el tramo de "Niños en edad escolar" (5 a 18 años) restando los bebés al grupo de menores de 19.
df['Age_5_18_Ptge'] = df['Age_under19_Ptge'] - df['Age_0-4_Ptge']

# Eliminamos 'Age_under19_Ptge' porque ya tenemos sus dos componentes desglosados (0-4 y 5-18)
# Esto evita la multicolinealidad perfecta.
df.drop(columns=['Age_under19_Ptge', 'check_sum'], inplace=True)
# Eliminamos 'Age_19_65_pct' ya que podemos obtener su valor a partir de los demás grupos de edad
df.drop(columns=['Age_19_65_pct'], inplace=True)
```

5. Análisis de valores atípicos

Para detectar los valores atípicos de las variables se aplicó la siguiente función basada en el IQR a cada una de ellas:

```
def analizar_atipicos_con_nombres(df, col, umbral=1.5, n_ejemplos=3):
    """
    Calcula outliers por IQR y muestra los nombres de los municipios (usando el índice).
    """
    serie = df[col].dropna()
    if serie.empty: return

    # Cálculo de límites (IQR)
    Q1 = serie.quantile(0.25)
    Q3 = serie.quantile(0.75)
    IQR = Q3 - Q1
    lim_inf = Q1 - umbral * IQR
    lim_sup = Q3 + umbral * IQR

    outliers = df[(df[col] < lim_inf) | (df[col] > lim_sup)]

    if not outliers.empty:
        print(f"\n{'='*50}")
        print(f" VARIABLE: {col}")
        print(f"\n{'='*50}")
        print(f"Total outliers: {len(outliers)} ({len(outliers)/len(df)*100:.2f}%)")
        print(f"Límites IQR ({umbral}x): [{lim_inf:.2f}, {lim_sup:.2f}]")

        # Ejemplos de valores ALTOS (Por encima del límite superior)
        altos = outliers[outliers[col] > lim_sup].sort_values(by=col, ascending=False).head(n_ejemplos)
        if not altos.empty:
            print(f"Ejemplos MÁS ALTOS:")
            for idx, row in altos.iterrows():
                print(f"    - {idx}: {row[col]:.2f}")

        # Ejemplos de valores BAJOS (Por debajo del límite inferior)
        bajos = outliers[outliers[col] < lim_inf].sort_values(by=col, ascending=True).head(n_ejemplos)
        if not bajos.empty:
            print(f"Ejemplos MÁS BAJOS:")
            for idx, row in bajos.iterrows():
                print(f"    - {idx}: {row[col]:.2f}")

    cols_numericas = df.select_dtypes(include=[np.number]).columns

    # Excluimos columnas target
    cols_excluir = ['Dcha_Pct', 'Derecha']
    cols_analisis = [c for c in cols_numericas if c not in cols_excluir]

    print("INFORME DE VALORES ATÍPICOS (Con Nombres del Índice)")

    for col in cols_analisis:
        analizar_atipicos_con_nombres(df, col)
```

VARIABLE: Population Total outliers: 1154 (44.22%) Límites IQR (1.5x): [-3225.50, 5818.50] Ejemplos MÁS ALTOS: - Madrid: 3141991.00 - Barcelona: 1604555.00 - Valencia: 785189.00	VARIABLE: SameComAutonDiffProvPtge Total outliers: 675 (8.32%) Límites IQR (1.5x): [-6.23, 12.18] Ejemplos MÁS ALTOS: - Riu de Cerdanya: 67.31 - Riells i Viabrea: 57.92 - Querol: 54.53	VARIABLE: IndustryUnemploymentPtge Total outliers: 247 (3.04%) Límites IQR (1.5x): [-21.43, 35.71] Ejemplos MÁS ALTOS: - Sacanet: 100.00 - Alcaldá de la Vega: 100.00 - Garaballa: 100.00	VARIABLE: Servicios Total outliers: 1274 (15.70%) Límites IQR (1.5x): [-60.00, 100.00] Ejemplos MÁS ALTOS: - Madrid: 177677.00 - Barcelona: 100010.00 - Valencia: 34526.00
VARIABLE: TotalCensus Total outliers: 1149 (14.16%) Límites IQR (1.5x): [-2414.50, 4397.50] Ejemplos MÁS ALTOS: - Madrid: 2363829.00 - Barcelona: 1136354.00 - Valencia: 578722.00	VARIABLE: DifComAutonPtge Total outliers: 388 (4.78%) Límites IQR (1.5x): [-8.50, 27.33] Ejemplos MÁS ALTOS: - Illán de Vacas: 100.00 - Ugena: 75.26 - El Viso de San Juan: 73.07	VARIABLE: ConstructionUnemploymentPtge Total outliers: 343 (4.23%) Límites IQR (1.5x): [-21.43, 35.71] Ejemplos MÁS ALTOS: - Villamiel de la Sierra: 100.00 - Bascuñana de San Pedro: 100.00 - Arrancacepas: 100.00	VARIABLE: Inmuebles Total outliers: 1050 (12.94%) Límites IQR (1.5x): [-1929.75, 3696.25] Ejemplos MÁS ALTOS: - Madrid: 1615548.00 - Barcelona: 857862.00 - Valencia: 458218.00
VARIABLE: Age_0-4_Ptge Total outliers: 28 (0.34%) Límites IQR (1.5x): [-3.33, 9.25] Ejemplos MÁS ALTOS: - Lantz: 13.24 - Valle de Egüés / Eguesibar: 12.86 - Renau: 11.92	VARIABLE: UnemployLess25_Ptge Total outliers: 225 (2.77%) Límites IQR (1.5x): [-15.70, 26.17] Ejemplos MÁS ALTOS: - Huerta de la Obispaia: 100.00 - Escanilla: 100.00 - Zorita de los Canes: 100.00	VARIABLE: ServicesUnemploymentPtge Total outliers: 702 (8.65%) Límites IQR (1.5x): [16.00, 105.33] Ejemplos MÁS ALTOS: - Zarzosa de Río Pisuerga: 0.00 - Fuente la Reina: 0.00 - Herbés: 0.00	VARIABLE: Pob2D10 Total outliers: 1142 (14.07%) Límites IQR (1.5x): [-3281.00, 5941.00] Ejemplos MÁS ALTOS: - Madrid: 3273040.00 - Barcelona: 1619337.00 - Valencia: 809267.00
VARIABLE: Age_over65_pct Total outliers: 59 (0.73%) Límites IQR (1.5x): [-5.79, 62.54] Ejemplos MÁS ALTOS: - Membre de la Hoz: 76.47 - Cereza de Peñahorcada: 75.31 - Valsalobre: 75.00	VARIABLE: Unemploy25_40_Ptge Total outliers: 1370 (16.88%) Límites IQR (1.5x): [1.43, 73.81] Ejemplos MÁS ALTOS: - Villanueva de Carazo: 100.00 - Castellfort: 100.00 - Espadilla: 100.00	VARIABLE: totalEmpresas Total outliers: 1198 (14.76%) Límites IQR (1.5x): [-203.00, 357.00] Ejemplos MÁS ALTOS: - Madrid: 299397.00 - Barcelona: 174209.00 - Valencia: 62013.00	VARIABLE: SUPERFICIE Total outliers: 723 (8.91%) Límites IQR (1.5x): [-5743.69, 14477.46] Ejemplos MÁS ALTOS: - Cáceres: 175022.91 - Librilla: 167520.39 - Badajoz: 144037.48
VARIABLE: WomanPopulationPtge Total outliers: 497 (6.12%) Límites IQR (1.5x): [39.31, 56.41] Ejemplos MÁS ALTOS: - Arenas del Rey: 72.68 - Monasterio: 69.23 - Villarejo de la Peña: 66.67	Ejemplos MÁS BAJOS: - Argelita: 0.00 - Castell de Cabres: 0.00 - Chodos / Xodos: 0.00	VARIABLE: Industria Total outliers: 1056 (13.01%) Límites IQR (1.5x): [-21.00, 35.00] Ejemplos MÁS ALTOS: - Madrid: 10521.00 - Barcelona: 5700.00 - Valencia: 2237.00	VARIABLE: PobChange_pct Total outliers: 372 (4.58%) Límites IQR (1.5x): [-26.13, 15.82] Ejemplos MÁS ALTOS: - Hornillos de Cameros: 138.46 - Yeberos: 136.91 - Moriscos: 91.35
Ejemplos MÁS BAJOS: - Bañuelos: 11.77 - Carrias: 13.04 - Toril y Masegoso: 16.67	VARIABLE: UnemployMore40_Ptge Total outliers: 1261 (15.54%) Límites IQR (1.5x): [13.55, 95.20] Ejemplos MÁS ALTOS: - Argelita: 100.00 - Castell de Cabres: 100.00 - Chodos / Xodos: 100.00	Ejemplos MÁS BAJOS: - Torrelara: 0.00 - Fresneda de la Sierra Tirón: 0.00 - Fuentebureba: 0.00	Ejemplos MÁS BAJOS: - Congostrina: -52.27 - Valsalobre: -46.67 - Gascuña de Bornova: -43.48
VARIABLE: ForeignersPtge Total outliers: 361 (4.45%) Límites IQR (1.5x): [-9.16, 19.59] Ejemplos MÁS ALTOS: - Rojales: 71.47 - Libier: 70.70 - Torre del Burgo: 68.86	VARIABLE: AgricultureUnemploymentPtge Total outliers: 519 (6.39%) Límites IQR (1.5x): [-17.61, 29.35] Ejemplos MÁS ALTOS: - Carrias: 100.00 - Tórtolas: 100.00 - Grandes y San Martín: 100.00	VARIABLE: Construcción Total outliers: 1094 (13.48%) Límites IQR (1.5x): [-37.50, 62.50] Ejemplos MÁS ALTOS: - Madrid: 30343.00 - Barcelona: 14271.00 - Zaragoza: 5362.00	VARIABLE: Personasinmueble Total outliers: 5 (0.06%) Límites IQR (1.5x): [-0.47, 3.05] Ejemplos MÁS ALTOS: - La Mojonera: 3.33 - Gurb: 3.21 - Rivas-Vaciamadrid: 3.21
VARIABLE: SameComAutonPtge Total outliers: 269 (3.31%) Límites IQR (1.5x): [53.83, 112.44] Ejemplos MÁS BAJOS: - Illán de Vacas: 0.00 - El Viso de San Juan: 15.41 - Ugena: 15.75		VARIABLE: ComercioHosteleria Total outliers: 1151 (14.18%) Límites IQR (1.5x): [-97.50, 162.50] Ejemplos MÁS ALTOS: - Madrid: 80856.00 - Barcelona: 51228.00 - Valencia: 20133.00	VARIABLE: Explotaciones Total outliers: 798 (9.83%) Límites IQR (1.5x): [-137.00, 287.00] Ejemplos MÁS ALTOS: - El Ejido: 4759.00 - Murcia: 4006.00 - Lorca: 3511.00
			VARIABLE: Age_5_18_Ptge Total outliers: 2 (0.02%) Límites IQR (1.5x): [-5.12, 26.49] Ejemplos MÁS ALTOS: - Castilleja de Guzmán: 28.13 - Cizur: 26.08

Tras analizar los datos detalladamente, se toma la decisión de la no eliminación de valores atípicos, justificando en los siguientes puntos algunos ejemplos del porqué:

- Municipios muy pequeños (<2500 habitantes) vs grandes ciudades (>1M habitantes).
- Zonas rurales vs urbanas con características socioeconómicas muy diferentes.
- Un municipio con alto % de población extranjera no es un error, es un caso real (ej: zonas turísticas cercanas a la costa).
- Municipios donde el 100% de los votos van a la izquierda o derecha.
- Municipios con 100% de población en actividad laboral.

Estamos analizando datos electorales de municipios españoles, y los puntos anteriormente mencionados, entre otros, son un ejemplo real de la heterogeneidad en España. Esta heterogeneidad es relevante para el análisis, por mucho que estadísticamente puedan parecer valores disparatados. Eliminar estos casos supondría la pérdida de información sobre la diversidad española. Además, los modelos de regresión lineal y logística son relativamente robustos a atípicos cuando el tamaño muestral es grande, las variables categóricas (“CCAA”, “Densidad”) capturarán parte de esta heterogeneidad estructural y,

por último, la validación cruzada nos permitirá evaluar si los atípicos afectan la generalización.

6. Análisis de valores perdidos

```
# Identificamos columnas con valores nulos
null_columns = df.columns[df.isnull().any()]

null_summary = pd.DataFrame(index=null_columns, columns=['Null Count', 'Null Percentage'])

for col in null_columns:
    null_summary.loc[col, 'Null Count'] = df[col].isnull().sum()
    null_summary.loc[col, 'Null Percentage'] = (df[col].isnull().sum() / len(df)) * 100

null_summary = null_summary.sort_values(by='Null Count', ascending=False)
null_summary
```

	Null Count	Null Percentage
ForeignersPtge	653	8.044844
Explotaciones	189	2.328446
Industria	188	2.316127
Construccion	139	1.712455
inmuebles	138	1.700136
PersonasInmueble	138	1.700136
Densidad	92	1.133424
Servicios	62	0.763829
ComercioHosteleria	9	0.110878
SUPERFICIE	8	0.098559
Pob2010	7	0.086239
PobChange_pct	7	0.086239
totalEmpresas	5	0.061599
Age_over65_pct	3	0.036959
SameComAutonPtge	3	0.036959

Debido a la variabilidad en el número de valores nulos, se decide implementar una estrategia diferenciada para los distintos casos: Eliminación de registros para las variables con menos de 10 valores nulos para mantener la integridad de los datos; imputación por mediana (ya que esta no se ve afectada por valores atípicos, y estamos ante una distribución asimétrica en la que hemos decidido conservar valores atípicos) para las variables con más de 10 valores nulos. Para la variable “Densidad” (excepción), se decide reemplazar los valores nulos por la moda, ya que es una variable categórica.

```
eliminar_nulos = list(null_summary.loc[null_summary['Null Count'] < 10].index)

df = df.dropna(subset=eliminar_nulos)

nulos_a_imputar = list(null_summary.loc[null_summary['Null Count'] > 10].index)
nulos_a_imputar.remove('Densidad')

for var in nulos_a_imputar:
    mediana = df[var].median()
    df[var] = df[var].fillna(mediana)

df['Densidad'] = df['Densidad'].fillna(df['Densidad'].mode()[0])


# Identificamos columnas con valores nulos
null_columns = df.columns[df.isnull().any()]

null_summary = pd.DataFrame(index=null_columns, columns=['Null Count', 'Null Percentage'])

for col in null_columns:
    null_summary.loc[col, 'Null Count'] = df[col].isnull().sum()
    null_summary.loc[col, 'Null Percentage'] = (df[col].isnull().sum() / len(df)) * 100

null_summary = null_summary.sort_values(by='Null Count', ascending=False)
null_summary
```

7. Detección de las relaciones entre las variables



Tras analizar la matriz de correlación, identificamos varios grupos de variables con correlaciones muy altas (>0.90) marcadas en rojo. Estas altas correlaciones pueden derivar en el problema de la multicolinealidad, por lo que hay que eliminar las variables redundantes manteniendo aquellas que sean más generales, aporten información única o tengan mejor calidad de datos:


Variables eliminadas y justificación:

1. ‘Pob2010’ (correlación 1.00 con ‘Population’)
 - Razón: Ambas miden lo mismo (población) en años muy cercanos.
 - Decisión: Mantener ‘Population’ (más reciente) y eliminar ‘Pob2010’.
2. ‘TotalCensus’ (correlación 1.00 con ‘Population’)
 - Razón: El censo total es prácticamente idéntico a la población.
 - Decisión: Mantener ‘Population’ como variable más general.
3. ‘inmuebles’ (correlación 0.99 con ‘Population’)
 - Razón: El número de inmuebles es directamente proporcional a la población.
 - Decisión: Mantener ‘PersonasInmueble’ (ratio) que aporta más información que el valor absoluto.

4. 'Industria', 'Construccion', 'ComercTTEHosteleria', 'Servicios' (correlación >0.95 con 'totalEmpresas')
 - Razón: Son componentes del total de empresas, por lo que están perfectamente correlacionadas
 - Decisión: Mantener 'ActividadPpal' (variable categórica que indica el sector predominante) que captura la información relevante sin multicolinealidad
5. 'SameComAutonPtge': la matriz de correlación revela un error que se nos ha pasado por alto. Tiene una alta correlación con 'DifComAutonPtge' (>0.8). Este bloque junto con 'SameComAutonDiffProvPtge' y 'ForeignersPtge', es el mismo caso que el bloque de la edad, entre todos suman el 100%. Eliminamos 'SameComAutonPtge' por considerarlo el más "natural", y lo tomamos como referencia.


Además de la multicolinealidad, la matriz de confusión nos permite observar las relaciones lineales de la variable objetivo 'Dcha_Pct' con el resto de las variables numéricas. Por ejemplo, para las variables de los porcentajes de personas por edad, nos damos cuenta de que existen correlaciones moderadas, siendo estas negativas excepto para las personas mayores de 65. Esto nos indica que las personas más jóvenes están más inclinadas hacia la izquierda, y las personas mayores de 65 años hacia la derecha. También existe una ligera correlación negativa entre el porcentaje de votos a la derecha y el porcentaje de población femenina, mostrando que las mujeres se ven más inclinadas hacia políticas de izquierdas. Por último, también destacamos una ligera correlación de la variable objetivo con 'PersonasInmueble', quizá asociado a densidad o urbanización.

Por otro lado, un análisis mediante la V de Cramer mide la asociación entre variables categóricas respecto a nuestra variable objetivo 'Derecha', en un rango entre 0 y 1, siendo 0 una asociación nula entre variables y 1 una asociación perfecta.



Para la variable objetivo 'Derecha' se observa una relación alta con 'CCAA' (valor de 0.7). El resto de las variables categóricas, 'ActividadPpal' y 'Densidad', poseen valores más bajos de relación (0.147 y 0.107).

Por último, para medir la influencia de las variables categóricas sobre nuestra variable objetivo continua 'Dcha_Pct', la métrica estadística correcta es la Eta Cuadrado.



Los resultados son similares a los de la variable 'Derecha', hay una relación evidente entre 'Dcha_Pct' y 'CCAA' con un Eta Cuadrado de 0.69. Las variables 'ActividadPpal' y 'Densidad' las podríamos considerar ruido.

8. Construcción del modelo de regresión lineal

```
data = df.copy()
X = data.drop(columns=['Dcha_Pct', 'Derecha'], axis=1)
y = data['Dcha_Pct']
var_cont = X.select_dtypes(include=['float64', 'int64']).columns.tolist()
var_categ = X.select_dtypes(include=['object']).columns.tolist()
```

Este primer paso para la regresión lineal consiste en, inicialmente, eliminar la variable binaria ('Derecha'), ya que es la variable objetivo de la regresión logística. Además, se separa la variable objetivo 'Dcha_Pct' del resto de variables predictoras. También se diferencia las variables categóricas de las continuas.

Una vez finalizado el primer paso, se hace una división del dataset en train y test (80% y 20% respectivamente), y posteriormente, procedemos a la construcción de modelos de regresión lineal basados en los métodos de selección de variables clásicos con los criterios AIC y BIC, estos son:

- Método Backward: Comienza con todas las variables en el modelo y va eliminando gradualmente las menos relevantes. En cada iteración, se prueba eliminar una de ellas y se observa el rendimiento del modelo con y sin ella. Si al eliminarla el modelo no es significativamente peor, se descarta. Una vez descartada una variable, no puede volver a entrar al modelo.
- Método Forward: Comienza con el modelo vacío y agrega variables progresivamente. Se inicia con la variable más relevante, y en cada iteración se

añade la que más mejora al rendimiento del modelo hasta alcanzar un conjunto óptimo de variables. Una vez añadida una variable al modelo, no puede salir.

- Método Stepwise: Este método combina los métodos anteriores, agrega variables que mejoran el rendimiento y elimina las menos significativas en cada iteración.
- AIC (Akaike Information Criterion): Se orienta a la capacidad predictiva, buscando el modelo que minimice la pérdida de información sin importar si el modelo es el "verdadero". Su penalización es constante, lo que lo hace más permisivo con la complejidad y propenso a incluir variables que mejoren el ajuste.
- BIC (Bayesian Information Criterion): Se basa en la probabilidad bayesiana y busca identificar el modelo real que generó los datos bajo un principio de parsimonia. Al penalizar en función del tamaño de la muestra, es más estricto que el AIC y tiende a seleccionar modelos más simples y robustos.

```
x_train, x_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=1234567)

modeloStepAIC = lm_stepwise(y_train, x_train, var_cont, var_categ, [], 'AIC')
modeloStepBIC = lm_stepwise(y_train, x_train, var_cont, var_categ, [], 'BIC')
modeloBackAIC = lm_backward(y_train, x_train, var_cont, var_categ, [], 'AIC')
modeloBackBIC = lm_backward(y_train, x_train, var_cont, var_categ, [], 'BIC')
modeloForwAIC = lm_forward(y_train, x_train, var_cont, var_categ, [], 'AIC')
modeloForwBIC = lm_forward(y_train, x_train, var_cont, var_categ, [], 'BIC')
```

Los modelos ya entrenados, se evaluaron tanto en train como en test mediante la métrica del R^2 , dejando los siguientes resultados:

Método	Métrica	R^2 Train	R^2 Test	Nº Parámetros
Backward	AIC	0.711883	0.713557	33
Backward	BIC	0.710638	0.711555	26
Forward	AIC	0.711883	0.713561	32
Forward	BIC	0.710638	0.711555	26
Stepwise	AIC	0.711883	0.713561	32
Stepwise	BIC	0.710638	0.711555	26

En un principio los modelos con criterio 'BIC' ofrecen resultados más óptimos debido a que hacen uso de un menor número de parámetros que los modelos 'AIC'. Aunque las métricas de R^2 son muy similares, el hecho de utilizar un menor número de parámetros, nos ofrece mejores resultados en términos parsimonia-rendimiento. Todos los modelos con criterio BIC han obtenido el mismo modelo, al igual que Forward y Stepwise AIC. No obstante, estos resultados no son suficientes para determinar un modelo ganador, por lo que sometemos a los modelos a un proceso de validación cruzada de 40 iteraciones, ya que ofrece más seguridad para garantizar la robustez de los modelos, aunque suponga una mayor carga computacional.

```

lista_modelos = {}
if 'modelos_generados' in locals():
    lista_modelos = modelos_generados.copy()
else:
    nombres_probables = ['modeloStepAIC', 'modeloStepBIC', 'modeloBackAIC', 'modeloBackBIC', 'modeloForwAIC', 'modeloForwBIC']
    for nombre in nombres_probables:
        if nombre in locals():
            lista_modelos[nombre] = locals()[nombre]

if not lista_modelos:
    print("No se encontraron modelos para validar. Asegúrate de ejecutar primero la selección de modelos.")
else:
    modelos_unicos = {}
    for nombre, modelo_res in lista_modelos.items():
        v_cont = tuple(sorted(modelo_res['Variables']['cont']))
        v_catg = tuple(sorted(modelo_res['Variables']['catg']))
        v_inter = tuple(sorted(modelo_res['Variables']['inter'])) if 'inter' in modelo_res['Variables'] else ()
        firma = (v_cont, v_catg, v_inter)

        if firma not in modelos_unicos:
            modelos_unicos[firma] = {
                'Nombre': nombre,
                'ModeloRes': modelo_res
            }

    # Bucle de Validación Cruzada (40 repeticiones x 5 folds)
    if 'y_train' not in locals() or 'x_train' not in locals():
        print("Error: 'y_train' o 'x_train' no están definidos.")
    else:
        results = pd.DataFrame({'Rsquared': [], 'Adj_Rsquared': [], 'Resample': [], 'Modelo': [], 'N_Params': []})
        n_repeticiones = 40
        n_folds = 5
        n_muestras = len(y_train)
        n_test_fold = n_muestras / n_folds # Aproximado

        print(f"\nIniciando validación cruzada para {len(modelos_unicos)} modelos únicos ((n_repeticiones) repeticiones de (n_folds)-fold CV)...")

        for rep in range(n_repeticiones):
            if (rep + 1) % 5 == 0:
                print(f"Repetición (rep + 1)/(n_repeticiones)...")

            results_rep = pd.DataFrame()

            for firma, info in modelos_unicos.items():
                nombre_mod = info['Nombre']
                vars_mod = info['ModeloRes']['Variables']
                n_params = len(info['ModeloRes']['Modelo'].params)

                r2_scores = validacion_cruzada_lm(
                    n_folds,
                    x_train,
                    y_train,
                    vars_mod['cont'],
                    vars_mod['catg'],
                    vars_mod.get('inter', [])
                )

                # Calcular R2 Ajustado manualmente para cada fold
                # Adj R2 = 1 - (1 - R2) * (n - 1) / (n - p - 1)
                adj_r2_scores = [1 - (1 - r2) * (n_test_fold - 1) / (n_test_fold - n_params - 1) for r2 in r2_scores]

                df_temp = pd.DataFrame({
                    'Rsquared': r2_scores,
                    'Adj_Rsquared': adj_r2_scores,
                    'Resample': [f'Rep{rep + 1}'] * n_folds,
                    'Modelo': [nombre_mod] * n_folds,
                    'N_Params': [n_params] * n_folds
                })

            results_rep = pd.concat([results_rep, df_temp], axis=0)

        results = pd.concat([results, results_rep], axis=0)

        print("\nValidación cruzada completada.")

```

```


Iniciando validación cruzada para 4 modelos únicos (40 repeticiones de 5-fold CV)...
Repetición 5/40...
Repetición 10/40...
Repetición 15/40...
Repetición 20/40...
Repetición 25/40...
Repetición 30/40...
Repetición 35/40...
Repetición 40/40...

Validación cruzada completada.

```

Mostramos lo resultados de este proceso:

Resumen Comparativo (Ordenado por R2 Ajustado):					
Modelo	R2_Mean	R2_Std	AdjR2_Mean	AdjR2_Std	N_Params
modeloStepBIC	0.708089	0.008900	0.702106	0.009083	26.0
modeloStepAIC	0.708514	0.009142	0.701127	0.009374	32.0
modeloBackAIC	0.708456	0.009114	0.700830	0.009352	33.0



Consideramos que los resultados de modelo StepwiseBIC son los más robustos y óptimos en términos parsimonia-rendimiento, y lo elegimos como modelo ganador.

OLS Regression Results						
=====						
Dep. Variable:	Dcha_Pct	R-squared:	0.711			
Model:	OLS	Adj. R-squared:	0.710			
Method:	Least Squares	F-statistic:	633.8			
Date:	Thu, 12 Feb 2026	Prob (F-statistic):	0.00			
Time:	09:37:04	log-likelihood:	-24561.			
No. Observations:	6478	AIC:	4.917e+04			
DF Residuals:	6452	BIC:	4.935e+04			
DF Model:	25					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]
const	41.4354	0.918	45.138	0.000	39.363	43.233
Age_over65_pct	0.2745	0.016	16.798	0.000	0.242	0.306
ForeignersPtte	0.1814	0.022	8.336	0.000	0.124	0.239
ServicesUnemploymentPtte	-0.0527	0.006	-8.518	0.000	-0.065	-0.041
IndustryUnemploymentPtte	-0.0510	0.012	-4.391	0.000	-0.074	-0.028
ConstructionUnemploymentPtte	-0.0348	0.011	-3.176	0.002	-0.055	-0.013
CCAA_Aragon	10.1567	0.666	15.248	0.000	8.851	11.462
CCAA_Asturias	3.4208	1.424	2.407	0.015	0.636	6.205
CCAA_Baleares	5.6252	1.578	3.565	0.000	2.532	8.718
CCAA_Canarias	3.9406	1.343	2.935	0.003	1.309	6.573
CCAA_Cantabria	17.2403	1.328	12.979	0.000	14.636	19.844
CCAA_CastillaLaLe	19.7860	0.567	34.921	0.000	18.675	20.897
CCAA_CastillaMacha	10.4813	0.626	16.907	0.000	9.266	11.697
CCAA_Cataluña	-26.8533	0.622	-43.185	0.000	-28.072	-25.634
CCAA_CoValenciana	5.4612	0.708	7.712	0.000	4.073	6.849
CCAA_Extremadura	4.0688	0.768	5.295	0.000	2.562	5.575
CCAA_Galicia	12.5617	0.850	14.770	0.000	10.895	14.229
CCAA_Madrid	15.7793	1.019	15.489	0.000	13.782	17.776
CCAA_Murcia	16.6993	1.747	9.559	0.000	13.275	20.124
CCAA_Navarra	-6.3583	0.890	-7.142	0.000	-8.103	-4.613
CCAA_PaísVasco	-31.2295	0.894	-34.927	0.000	-32.982	-29.477
CCAA_Rioja	14.7299	1.046	14.078	0.000	12.679	16.781
Densidad_Baja	-2.5237	0.650	-3.880	0.000	-3.799	-1.249
Densidad_MuyBaja	-3.8611	0.640	-6.030	0.000	-5.116	-2.606
ActividadPpal_Otro	0.3113	0.410	0.759	0.448	-0.493	1.115
ActividadPpal_Servicios	3.2149	0.596	5.390	0.000	2.046	4.384
=====						
Omnibus:	132.086	Durbin-Watson:	1.991			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	280.812			
Skew:	-0.049	Prob(JB):	1.05e-61			
Kurtosis:	4.015	Cond. No.	1.12e+03			

TABLA DE SIGNIFICANCIA (Ordenada)				
=====				
Códigos: '***' < 0.001, '**' < 0.01, '*' < 0.05, '.' < 0.1				
	Coefficiente	Std. Error	t-value	
const	41.435431	0.917972	45.138000	
CCAA_Cataluña	-26.853321	0.621819	-43.185142	
CCAA_PaísVasco	-31.229521	0.894132	-34.927175	
CCAA_CastillaLeón	19.785988	0.566592	34.921076	
CCAA_CastillaLaMancha	18.481327	0.619939	16.907036	
Age_over65_pct	0.274459	0.061339	16.797926	
CCAA_Madrid	15.779251	1.018720	15.489295	
CCAA_Aragón	10.156658	0.666078	15.248448	
CCAA_Galicia	12.561711	0.850464	14.778425	
CCAA_Rioja	14.729914	1.046277	14.078489	
CCAA_Cantabria	17.248270	1.328328	12.978929	
CCAA_Murcia	16.699340	1.747038	9.558657	
ServicesUnemploymentPtge	-0.052715	0.006189	-8.517867	
ForeignersPtge	0.181404	0.021762	8.335838	
CCAA_ComValenciana	5.461157	0.708145	7.711916	
CCAA_Navarra	-6.358250	0.890211	-7.142469	
Densidad_MuyBaja	-3.861100	0.640366	-6.029519	
ActividadPpal_Servicios	3.214938	0.596444	5.390178	
CCAA_Extremadura	4.068778	0.768387	5.295219	
IndustryUnemploymentPtge	-0.059800	0.011611	-4.930602	
Densidad_Baja	-2.523723	0.650474	-3.879822	
CCAA_Baleares	5.625225	1.577791	3.565523	
ConstructionUnemploymentPtge	-0.033997	0.010705	-3.175834	
CCAA_Canarias	3.940633	1.342660	2.934944	
CCAA_Asturias	3.427953	1.424075	2.407143	
ActividadPpal_Otro	0.311301	0.410106	0.759075	
=====				
		P-Valor	Signif.	
const	0.000000e+00	***		
CCAA_Cataluña	0.000000e+00	***		
CCAA_PaísVasco	5.912470e-245	***		
CCAA_CastillaLeón	7.073386e-245	***		
CCAA_CastillaLaMancha	8.838345e-63	***		
Age_over65_pct	5.175410e-62	***		
CCAA_Madrid	3.687774e-53	***		
CCAA_Aragón	1.327396e-51	***		
CCAA_Galicia	1.403107e-48	***		
CCAA_Rioja	2.326349e-44	***		
CCAA_Cantabria	4.809315e-38	***		
CCAA_Murcia	1.655106e-21	***		
ServicesUnemploymentPtge	2.009666e-17	***		
ForeignersPtge	9.315375e-17	***		
CCAA_ComValenciana	1.426782e-14	***		
CCAA_Navarra	1.017823e-12	***		
Densidad_MuyBaja	1.735375e-09	***		
ActividadPpal_Servicios	7.288243e-08	***		
CCAA_Extremadura	1.228025e-07	***		
IndustryUnemploymentPtge	1.148414e-05	***		
Densidad_Baja	1.055737e-04	***		
CCAA_Baleares	3.661362e-04	***		
ConstructionUnemploymentPtge	1.501101e-03	**		
CCAA_Canarias	3.347843e-03	**		
CCAA_Asturias	1.610578e-02	*		
ActividadPpal_Otro	4.478352e-01			

Si echamos un vistazo a las variables continuas, 'Age_over65_pct' es la variable continua con mayor impacto y significancia ($t = 16.8$, $p < 0.001$). El coeficiente de 0.274 sugiere una relación positiva: por cada punto porcentual de incremento en la población mayor de 65 años, el voto a la derecha aumenta, en promedio, 0.27%. Esto refuerza la teoría que vincula el envejecimiento demográfico con comportamientos electorales más conservadores. 'ServicesUnemploymentPctge' presenta una relevancia notable ($t = -8.51$, $p < 0.001$). El coeficiente es negativo (-0.0527), indicando que un mayor desempleo en este sector se correlaciona con una disminución en el porcentaje de voto a la derecha. Este resultado es de especial interés para el análisis de economía política, sugiriendo que la precariedad en el sector terciario podría estar desplazando el voto hacia opciones progresistas.

En las variables categóricas, 'CCAA' es la dimensión de mayor peso en el modelo. Destacan Cataluña (coef = -26.85, $t = -43.185$) y País Vasco (coef = -31.22, $t = -34.92$), cuyos coeficientes negativos extremadamente altos reflejan el peso del nacionalismo en esas zonas. En sentido opuesto, Castilla y León (coef = 19.78, $t = 34.92$) actúa como el principal bastión del voto de derecha. Estos resultados evidencian que, en el contexto español, la identidad regional y la estructura de partidos autonómica son factores explicativos mucho más potentes que cualquier variable socioeconómica individual. La densidad de población ('Densidad_MuyBaja' y 'Densidad_Baja') emerge como el segundo factor categórico más relevante ($t = -6.02$ para densidad muy baja). Los coeficientes negativos (-3.86 y -2.52) sugieren que los municipios de baja densidad tienden a votar menos a la derecha que la categoría de referencia (presumiblemente zonas urbanas de alta densidad). Este hallazgo es contraintuitivo respecto a la narrativa de la "España vaciada" como inherentemente conservadora, sugiriendo que dicha tendencia podría explicarse más por la edad que por la densidad.

Este modelo se consolida como ganador debido a un equilibrio óptimo entre parsimonia y capacidad explicativa.

- Bondad de Ajuste (R^2): El modelo alcanza un R^2 de 0.711, lo que significa que es capaz de explicar el 71.1% de la variabilidad del voto a la derecha. En el contexto de elecciones, donde el comportamiento humano introduce un alto grado de incertidumbre aleatoria, un ajuste superior al 70% se considera excepcionalmente alto. Además, el R^2 ajustado (0.710) es prácticamente idéntico al nominal, lo que penaliza la inclusión de variables innecesarias y confirma que el modelo no padece de *overfitting*.
- Significancia Global (Estadístico F): Con un F-statistic de 633.8 y un p-valor de 0.00, el modelo posee una validez estadística indiscutible. Esto permite rechazar la hipótesis nula de que todos los coeficientes son iguales a cero, asegurando que la combinación de variables demográficas, económicas y regionales tiene un impacto sistemático y real sobre el resultado electoral estudiado.
- Robustez y Parsimonia: El modelo utiliza 25 grados de libertad para analizar una muestra amplia de 6,478 observaciones. A pesar de la complejidad del mapa autonómico español, la gran mayoría de los predictores son significativos al nivel


del 1% ($p < 0.01$). Variables como la edad ('Age_over65_pct') y las dummies regionales muestran estadísticos t muy elevados, lo que garantiza que los efectos encontrados son consistentes y no dependen de unos pocos casos aislados.

- Diagnóstico de Multicolinealidad: El *Condition Number* 1,120. Aunque este valor supera ligeramente el umbral teórico de 1,000, es un resultado esperado y aceptable dado que el modelo incluye un set completo de variables categóricas para las Comunidades Autónomas. En estudios territoriales, es común que la localización geográfica esté correlacionada con factores socioeconómicos, pero la estabilidad de los coeficientes y sus bajos errores estándar indican que esta multicolinealidad no compromete la interpretación de los resultados.
- Análisis de Residuos: El estadístico Durbin-Watson de 1.991 es casi perfecto, lo que indica una ausencia total de autocorrelación en los residuos.

Aún así, el modelo puede ser mejorable, y estas son algunas recomendaciones para mejorar el modelo de manera manual:

- Depuración de variables no significativas: La variable 'ActividadPpal_Otro' presenta un p-valor de 0.448, lo que indica que no tiene un impacto estadísticamente significativo sobre el voto a la derecha. Su eliminación es fundamental para aplicar el principio de parsimonia: simplificar la estructura del modelo y evitar el ruido innecesario.
- Agrupación de la estructura regional: Aunque las variables de Comunidad Autónoma son los predictores más potentes, algunas presentan coeficientes con errores estándar relativamente altos o p-valores menos robustos ('CCAA_Asturias', $p=0.016$). Podríamos estudiar como agruparlas, siempre y cuando no sea en base a su intención de voto a la derecha, ya que el "razonamiento circular" forzaría el modelo al éxito, perdiendo poder explicativo.
- Incorporación de 'PobChange_pct': El modelo actual utiliza la densidad de población como una variable fija. Sustituir o complementar las variables de Densidad con el cambio poblacional permitiría capturar el fenómeno de la "España Vacía". Un municipio que pierde población rápidamente tiende a desarrollar un voto de resistencia o descontento mucho más marcado que uno que, siendo pequeño, mantiene su censo estable.
- Interacción entre Edad y Sector Económico: Dado que tanto 'Age_over65_pct' como el desempleo sectorial son significativos, sería interesante añadir un término de interacción entre ambos. Esto permitiría testar si el impacto del desempleo en servicios afecta de la misma manera al voto en municipios envejecidos que en municipios jóvenes.
- Manejar los datos atípicos aplicando una transformación logarítmica. Esta técnica suaviza las diferencias extremas (ej: $\log(\text{Population})$ acerca a Madrid al resto de la distribución) y suele mejorar el rendimiento de la Regresión Lineal, haciendo que los residuos sean más normales.

Vamos a evaluar el modelo ganador, y a graficar la regresión lineal con sus resultados:



En cuanto a los gráficos de Train y Test, lo primero que se percibe es que el modelo es robusto al pasar de train a test. Los resultados son prácticamente idénticos: el R^2 se queda 0.71 y el error (RMSE) apenas cambia, lo que significa que el modelo no ha aprendido los datos de memoria (no hay *overfitting*) y sabe generalizar bien. Sin embargo, en ambos gráficos se aprecia que los puntos no forman una sola línea, sino que están separados en dos grupos. El modelo intenta pasar por el medio de todo, pero le cuesta un poco entender por qué los datos están tan divididos, especialmente en los valores más altos donde los puntos se dispersan más.

Por el lado del gráfico de Residuos, se ve un hueco notable en el medio, entre el valor predicho 22 y 32 aproximadamente, lo que confirma que hay algo en los datos que el modelo lineal no está pillando, como si faltara una variable importante que de más sentido. Además, la "mancha" de puntos de la derecha es mucho más grande y ancha que la de la izquierda; esto nos dice que el modelo es bastante preciso cuando predice valores bajos, pero cuando intenta predecir valores altos se vuelve mucho más impreciso y falla por más margen. Aunque el modelo es estable, los residuos nos avisan de que una simple línea recta no es suficiente para explicar toda la historia de los datos, lo cual es comprensible teniendo en cuenta de que estamos hablando de votos en elecciones. El hecho de que varias personas vivan en el mismo sitio, tengan el mismo trabajo o compartan sus raíces no garantiza que voten igual. Esto demuestra que la intención de voto es algo mucho más complejo y volátil que solo el perfil de la persona.

9. Construcción del modelo de regresión logística

Al igual que en el caso de la regresión lineal, para la regresión logística, lo primero es eliminar en este caso la variable 'Dcha_Pct', ya que era la variable objetivo de la regresión

lineal. Así mismo, como en el caso de la regresión lineal, se separa la variable objetivo ‘Derecha’ del resto de variables, se diferencian variables numéricas de categóricas, y se realiza la división entre los conjuntos de train y test. El código y métodos empleados fueron los mismos que para la regresión lineal, con la particularidad de que, en lugar de la función `lm_método`, se utilizó `glm_método` al tratarse de una regresión logística.

```
data_log = df.copy()
X_log = data_log.drop(columns=['Dcha_Pct', 'Derecha'], axis=1)
y_log = data_log['Derecha']


var_cont_log = X_log.select_dtypes(include=['float64', 'int64']).columns.tolist()
var_categ_log = X_log.select_dtypes(include=['object']).columns.tolist()

x_train_log, x_test_log, y_train_log, y_test_log = train_test_split(X_log, y_log, test_size=0.2, random_state=1234567)

modelologStepAIC = glm_stepwise(y_train_log, x_train_log, var_cont_log, var_categ_log, [], 'AIC')
modelologStepBIC = glm_stepwise(y_train_log, x_train_log, var_cont_log, var_categ_log, [], 'BIC')
modelologBackAIC = glm_backward(y_train_log, x_train_log, var_cont_log, var_categ_log, [], 'AIC')
modelologBackBIC = glm_backward(y_train_log, x_train_log, var_cont_log, var_categ_log, [], 'BIC')
modelologForwAIC = glm_forward(y_train_log, x_train_log, var_cont_log, var_categ_log, [], 'AIC')
modelologForwBIC = glm_forward(y_train_log, x_train_log, var_cont_log, var_categ_log, [], 'BIC')
```

Los modelos ya entrenados, se evaluaron tanto en train como en test, pero esta vez es AUC la métrica que se utiliza para comparar el rendimiento de los modelos:


Método	Métrica	AUC Train	AUC Test	Nº Parámetros
Backward	AIC	0.893538	0.907893	22
Backward	BIC	0.893538	0.907893	22
Forward	AIC	0.893739	0.907116	23
Forward	BIC	0.893538	0.907895	22
Stepwise	AIC	0.893739	0.907116	23
Stepwise	BIC	0.893538	0.907895	22



Todos los modelos presentan métricas muy similares. Forward y Stepwise AIC utilizan un parámetro más pero ofrecen la mejor métrica en train, pero la peor en test, indicando que puede ser el que peor generaliza. Entre Forward y Stepwise BIC y los modelos Backward, la diferencia es mínima, pero la métrica en test de Forward y Stepwise BIC es ligeramente superior, por lo que en un principio serían el modelo ganador. No obstante, al igual que en la regresión lineal, esto no es suficiente para determinar un modelo

ganador, por lo que sometemos también estos modelos a un proceso de regresión lineal de 40 iteraciones. El código es prácticamente idéntico al de regresión lineal.

```
Nota: 'Backward BIC' es idéntico a 'Backward AIC'. Se evaluará solo una vez.  
Nota: 'Forward BIC' es idéntico a 'Forward AIC'. Se evaluará solo una vez.  
Nota: 'Stepwise BIC' es idéntico a 'Stepwise AIC'. Se evaluará solo una vez.  
  
Iniciando validación cruzada para 3 modelos únicos (40 reps de 5-fold CV)...  
Repetición 5/40...  
Repetición 10/40...  
Repetición 15/40...  
Repetición 20/40...  
Repetición 25/40...  
Repetición 30/40...  
Repetición 35/40...  
Repetición 40/40...
```



Los resultados de la validación cruzada respaldan lo que hemos comentado anteriormente, las métricas de Forward BIC son algo superiores, por lo que lo determinamos como modelo ganador.

El siguiente apartado, es realizar un análisis para determinar el punto de corte óptimo. Se va a utilizar el punto de corte de Youden, que, en regresión logística, es el umbral que maximiza la suma de sensibilidad y especificidad, buscando el mejor equilibrio entre aciertos en positivos y negativos, y se comparará con el punto de corte que maximiza el *Accuracy*. Se usa para elegir el punto óptimo de clasificación en lugar del típico 0.5. Se realizó con el siguiente código:

```

modelo_ganador = modeloLogForwBIC
nombre_modelo = "Forward BIC"

# Preparar datos de test una sola vez
interacciones = modelo_ganador['Variables']['inter'] if 'inter' in modelo_ganador['Variables'] else []
x_test_modelo = crear_data_modelo(
    x_test_log,
    modelo_ganador['Variables']['cont'],
    modelo_ganador['Variables']['categ'],
    interacciones
)

# Obtener probabilidades (Predicciones continuas)
probs_test = modelo_ganador['Modelo'].predict_proba(x_test_modelo)[1, :]

cortes = np.arange(0.01, 1.0, 0.01)
resultados_corte = []

for c in cortes:
    preds = (probs_test > c).astype(int)

    tn, fp, fn, tp = confusion_matrix(y_test_log, preds).ravel()

    acc = (tp + tn) / (tp + tn + fp + fn)
    sens = tp / (tp + fn) if (tp + fn) > 0 else 0
    spec = tn / (tn + fp) if (tn + fp) > 0 else 0
    youden = sens + spec - 1

    resultados_corte.append({
        'Corte': c,
        'Accuracy': acc,
        'Sensibilidad': sens,
        'Especificidad': spec,
        'Youden': youden
    })

df_metricas = pd.DataFrame(resultados_corte)

# Determinar los mejores puntos de corte
idx_max_acc = df_metricas['Accuracy'].idxmax()
idx_max_youden = df_metricas['Youden'].idxmax()

mejor_corte_acc = df_metricas.loc[idx_max_acc]
mejor_corte_youden = df_metricas.loc[idx_max_youden]

print("\n--- MEJORES PUNTOS DE CORTE ---")
print(f"Maximizando Accuracy: Corte = {mejor_corte_acc['Corte']:.2f}")
print(f"Maximizando Youden: Corte = {mejor_corte_youden['Corte']:.2f}")

# Mostrar métricas para esos puntos
resumen_cortes = pd.DataFrame([mejor_corte_acc, mejor_corte_youden])
resumen_cortes.index = ['Max Accuracy', 'Max Youden']
print("\nComparativa de Métricas:")
display(resumen_cortes)

```


```


--- MEJORES PUNTOS DE CORTE ---
Maximizando Accuracy: Corte = 0.46
Maximizando Youden: Corte = 0.51

```

Comparativa de Métricas:

	Corte	Accuracy	Sensibilidad	Especificidad	Youden
Max Accuracy	0.46	0.853086	0.927992	0.736593	0.664585
Max Youden	0.51	0.853086	0.920892	0.747634	0.668527





Un fenómeno destacable es que el *Accuracy* es idéntico para ambos puntos de corte (0.853 tanto en 0.46 como en 0.51). Esto elimina el dilema habitual de "sacrificar precisión", permitiéndonos enfocar la decisión puramente en la calidad de la discriminación entre clases. Aunque el umbral de 0.46 ofrece una Sensibilidad marginalmente superior (92.8% vs 92.1%), lo hace a costa de aceptar más falsos positivos. Al desplazarnos al corte de 0.51, logramos aumentar la Especificidad al 74.8% (frente al 73.6% del otro corte). En el contexto electoral, elegir 0.51 es preferible porque sitúa el umbral en una zona de "mayor certeza" (por encima del 50% neutral). Esto reduce el sesgo de sobreestimación hacia la clase positiva ("Derecha") y maximiza el Índice de Youden (0.669), garantizando que el modelo es más competente distinguiendo lo que no es la clase objetivo, sin perder ni una décima de exactitud general. En conclusión, nos quedamos con 0.51 porque obtenemos la misma tasa de aciertos totales, pero con una distribución de errores más higiénica (menos falsos positivos) y un umbral lógicamente más coherente.

A continuación, vemos el cuadro resumen del modelo Forward BIC (modelo ganador), y comentamos sus resultados:

RESUMEN ESTADÍSTICO (Statsmodels Refit)						
Logit Regression Results						
Dep. Variable:	Derecha	No. Observations:	6478			
Model:	Logit	Df Residuals:	6456			
Method:	MLE	Df Model:	21			
Date:	Thu, 12 Feb 2025	Pseudo R-squ.:	0.4318			
Time:	10:24:13	Log-likelihood:	-2436.4			
converged:	True	LL-Null:	-4288.0			
Covariance Type:	nonrobust	LLR p-value:	0.000			
	coef	std err	z	P> z	[0.025	0.975]
const	-2.1173	0.158	-13.377	0.000	-2.428	-1.807
ForeignersPtge	0.0400	0.006	6.305	0.000	0.028	0.052
Age_over65_pct	0.0210	0.004	4.841	0.000	0.013	0.030
Explotaciones	0.0009	0.000	4.495	0.000	0.000	0.001
CCAA_Aragón	1.6185	0.143	11.299	0.000	1.338	1.899
CCAA_Asturias	0.7666	0.277	2.769	0.006	0.224	1.309
CCAA_Baleares	0.9165	0.327	2.799	0.005	0.275	1.558
CCAA_Canarias	1.7711	0.277	6.399	0.000	1.229	2.313
CCAA_Cantabria	3.6886	0.440	8.375	0.000	2.825	4.552
CCAA_CastillaLeón	3.2467	0.142	22.846	0.000	2.968	3.525
CCAA_CastillaMancha	1.8307	0.135	13.594	0.000	1.567	2.095
CCAA_Cataluña	-5.2442	0.721	-7.278	0.000	-6.656	-3.832
CCAA_ComValenciana	3.3169	0.205	16.161	0.000	2.915	3.719
CCAA_Extremadura	0.6760	0.157	4.298	0.000	0.368	0.984
CCAA_Galicia	4.2157	0.343	12.277	0.000	3.543	4.889
CCAA_Madrid	3.2757	0.325	10.077	0.000	2.639	3.913
CCAA_Murcia	2.9902	0.543	5.505	0.000	1.926	4.055
CCAA_Navarra	0.2949	0.185	1.592	0.111	-0.068	0.658
CCAA_PaisVasco	-2.5136	0.467	-5.385	0.000	-3.429	-1.599
CCAA_Rioja	2.7655	0.272	10.172	0.000	2.233	3.298
ActividadPpal_Otro	0.2597	0.108	2.397	0.017	0.047	0.472
ActividadPpal_Servicios	1.2028	0.201	5.984	0.000	0.809	1.597

TABLA DE SIGNIFICANCIA (Ordenada por P-Valor)				
	Coefficiente	Std. Error	z-value	P-Valor
CCAA_CastillaLeón	3.246749	0.142117	22.845574	1.617197e-115
CCAA_ComValenciana	3.316941	0.205246	16.160807	9.530594e-59
CCAA_CastillaMancha	1.830655	0.134667	13.593945	4.349905e-42
const	-2.117315	0.158275	-13.377431	8.193078e-41
CCAA_Galicia	4.215733	0.343389	12.276831	1.206312e-34
CCAA_Aragón	1.618456	0.143242	11.298770	1.330684e-29
CCAA_Rioja	2.765455	0.271877	10.171712	2.652049e-24
CCAA_Madrid	3.275738	0.325057	10.077436	6.951647e-24
CCAA_Cantabria	3.688582	0.440411	8.375313	5.507725e-17
CCAA_Cataluña	-5.244233	0.720529	-7.278314	3.380166e-13
CCAA_Canarias	1.771052	0.276759	6.399268	1.561233e-10
ForeignersPtge	0.040049	0.006352	6.304822	2.885249e-10
ActividadPpal_Servicios	1.202792	0.200995	5.984183	2.174782e-09
CCAA_Murcia	2.990232	0.543164	5.505207	3.687342e-08
CCAA_PaisVasco	-2.513589	0.466807	-5.384646	7.258744e-08
Age_over65_pct	0.021036	0.004346	4.840614	1.294385e-06
Explotaciones	0.000864	0.000192	4.495025	6.956179e-06
CCAA_Extremadura	0.675971	0.157277	4.297961	1.723767e-05
CCAA_Baleares	0.916470	0.327443	2.798867	5.128231e-03
CCAA_Asturias	0.766581	0.276813	2.769309	5.617529e-03
ActividadPpal_Otro	0.259706	0.108354	2.396818	1.653815e-02
CCAA_Navarra	0.294854	0.185248	1.591673	1.114582e-01
	Signif.			
CCAA_CastillaLeón	***			
CCAA_ComValenciana	***			
CCAA_CastillaMancha	***			
const	***			
CCAA_Galicia	***			
CCAA_Aragón	***			
CCAA_Rioja	***			
CCAA_Madrid	***			
CCAA_Cantabria	***			
CCAA_Cataluña	***			
CCAA_Canarias	***			
ForeignersPtge	***			
ActividadPpal_Servicios	***			
CCAA_Murcia	***			
CCAA_PaisVasco	***			
Age_over65_pct	***			
Explotaciones	***			
CCAA_Extremadura	***			
CCAA_Baleares	**			
CCAA_Asturias	**			
ActividadPpal_Otro	*			
CCAA_Navarra				

ODDS RATIOS (Exp(Coef))	
CCAA_Galicia	67.743823
CCAA_Cantabria	39.988113
CCAA_ComValenciana	27.575874
CCAA_Madrid	26.462743
CCAA_CastillaLeón	25.706625
CCAA_Murcia	19.890287
CCAA_Rioja	15.886259
CCAA_CastillaMancha	6.237970
CCAA_Canarias	5.877034
CCAA_Aragón	5.045292
ActividadPpal_Servicios	3.329400
CCAA_Baleares	2.500448
CCAA_Asturias	2.152394
CCAA_Extremadura	1.965942
CCAA_Navarra	1.342931
ActividadPpal_Otro	1.296549
ForeignersPtge	1.040862
Age_over65_pct	1.021259
Explotaciones	1.000864
const	0.120354
CCAA_PaísVasco	0.080977
CCAA_Cataluña	0.005278
dtype: float64	

En las variables continuas, ‘ForeignersPtge’ emerge como el predictor continuo más relevante. El coeficiente positivo (0.04) y un Odds Ratio (OR) de 1.041 sugieren que, por cada incremento de un punto porcentual en la población extranjera, la probabilidad de observar la variable "Derecha" aumenta en un 4.1%. Este fenómeno podría estar vinculado a dinámicas de movilización política en zonas con alta presión demográfica migratoria, y el posible descontento con la política de izquierdas del país de origen de las personas migrantes. ‘Age_over65_pct’ obtiene una relación positiva y significativa (Coef. 0.0210; $p = 0.000$). Con un OR de 1.021, el envejecimiento poblacional actúa como un predictor incremental: un aumento unitario en el porcentaje de población mayor de 65 años eleva las posibilidades de voto a la derecha en un 2.1%. Estadísticamente, esto refuerza la tesis de la correlación entre demografía madura y tendencia conservadora.

En cuanto a las variables categóricas, el factor territorial y la estructura económica sectorial son los principales determinantes de la varianza del modelo (Pseudo $R^2 = 0.4318$). ‘CCAA’ es la variable con mayor peso explicativo. Cabe destacar dos contrastes regionales extremos: Galicia presenta el efecto positivo más potente del modelo (Coef. 4.2157). Su Odds Ratio de 67.74 es muy alto, indicando que, el hecho de residir en Galicia multiplica exponencialmente la probabilidad de ‘Derecha’. Cataluña, en el espectro opuesto, muestra un coeficiente fuertemente negativo (-5.2442) y un OR cercano a cero (0.005). Esto señala una divergencia estructural profunda en el comportamiento de la variable dependiente para este territorio, siendo el predictor negativo más robusto del modelo. La estructura económica del municipio también resulta determinante, especialmente la categoría Servicios. Con un coeficiente de 1.2028 y un OR de 3.329, el predominio del sector servicios aumenta significativamente las probabilidades de la variable "Derecha" (233% más que la categoría base). Este resultado sugiere que los entornos con economías terciarizadas presentan una inclinación política distinta a los entornos industriales o primarios.

El modelo de regresión logística ganador demuestra un equilibrio óptimo entre capacidad discriminante, parsimonia y coherencia teórica.

- Bondad de Ajuste y Capacidad Explicativa: El indicador más contundente de la calidad del modelo es su Pseudo R^2 de 0.4318. En contextos donde no aplica el

R^2 convencional de OLS, valores dentro del rango de 0.2 a 0.4 se consideran indicativos de un ajuste excelente. Superar el umbral del 0.4 en un estudio electoral sugiere que el modelo ha capturado con una precisión excepcional la estructura que discrimina entre municipios de "Derecha" y el resto. Asimismo, la reducción de la Log-Likelihood desde el modelo nulo ($LL_{\{null\}} = -4288.0$) hasta el modelo ajustado ($LL_{\{model\}} = -2436.4$) demuestra que la inclusión de los predictores disminuye la incertidumbre del modelo, explicando gran parte de la varianza original.

- Significancia Global y Robustez Estadística: El estadístico LLR p-value de 0.000 permite rechazar con total seguridad la hipótesis nula global, certificando que el conjunto de variables aporta información estadísticamente significativa frente a un modelo vacío. El modelo emplea 21 grados de libertad para explicar un dataset de 6,478 observaciones. Esta relación (aproximadamente 308 observaciones por parámetro estimado) garantiza la estabilidad de los estimadores, minimizando el riesgo de *overfitting*. La convergencia exitosa del algoritmo de Máxima Verosimilitud (MLE) confirma, además, que el modelo es numéricamente estable y carece de problemas de multicolinealidad perfecta que pudieran sesgar los errores estándar.
- Especificación Depurada y Significancia Individual: El análisis de los z-scores revela una especificación altamente eficiente. De los 22 coeficientes estimados (incluyendo la constante), 20 alcanzan significancia estadística al nivel de confianza estándar del 95% ($p < 0.05$), y 17 de ellos son significativos al 99.9% ($p < 0.001$). La única excepción notable es CCAA_Navarra ($p=0.111$), lo cual es un hallazgo en sí mismo (indica que no se diferencia significativamente de la categoría base), mientras que el resto de variables territoriales actúan como predictores robustos.
- Capacidad de Cuantificación de la Heterogeneidad: La gran fortaleza del modelo reside en los Odds Ratios (OR), que permiten establecer una jerarquía clara en los determinantes del voto. El modelo logra capturar que el factor territorial es el "driver" principal, mientras que modula estos efectos base con variables socioeconómicas precisas, como la terciarización de la economía ('ActividadPpal_Servicios').


Para elevar la calidad del modelo de regresión logística, se presentan una serie de propuestas que se podrían llevar a cabo para la optimización manual del modelo:

- Exclusión de 'CCAA_Navarra': Con un p-valor de 0.111, esta variable no alcanza el umbral de significancia estándar ($p < 0.05$), lo que indica que su contribución marginal al modelo es nula en comparación con la categoría de referencia.
- Diagnóstico de Multicolinealidad (VIF) en Variables Estructurales: Aunque el modelo converge, los coeficientes extremos observados en variables territoriales como Galicia o Cataluña sugieren una alta correlación con otras variables. Sería conveniente calcular el Factor de Inflación de la Varianza (VIF) para confirmar que no existe redundancia explicativa entre las variables demográficas

(‘Age_over65_pct’, ‘Explotaciones’) y las variables geográficas. Por ejemplo, si las zonas con más Explotaciones (agrícolas) coinciden sistemáticamente con una CCAA específica, los errores estándar podrían estar inflados, afectando la precisión de los intervalos de confianza.

- ‘ActividadPpal_Otro’: Si bien es estadísticamente significativa ($p=0.017$), es la variable con la menor significancia (z-score más bajo, 2.39) después de Navarra. Su Odds Ratio de 1.29 es modesto. En busca de un modelo más parsimonioso, se podría evaluar si esta categoría aporta información sustantiva real o si podría agruparse con la categoría base del sector económico.

Por último, vamos a comprobar la capacidad de nuestro modelo ganador para predecir nuestra variable objetivo ‘Derecha’. Visualizamos los resultados en una matriz de confusión:



Al utilizar el modelo Forward BIC con un punto de corte de 0.51 (basado en el índice de Youden), se observa una clara priorización de la capacidad de detección, alcanzando una sensibilidad sobresaliente del 92.09% frente a una especificidad del 74.76%. Dado que el umbral es prácticamente neutro (muy cercano al estándar 0.5), el modelo demuestra una tendencia natural a capturar la mayoría de los casos positivos, logrando una precisión del 85.02% que asegura una alta fiabilidad cuando predice la clase "Derecha". Con una *Accuracy* del 85.31%, el clasificador muestra un desempeño muy sólido. Lo más destacable es la minimización de los falsos negativos (apenas un 4.81%); esto confirma que la selección de variables ha generado un modelo ideal para escenarios donde es crítico no omitir ningún caso real de "Derecha", manteniendo un poder predictivo excelente.