



‘Minería de datos y modelización predictiva’

‘Series temporales’

Pablo Blas Hernández

1. Introducción: Presentación de la serie a analizar

Para la realización de este proyecto de análisis de series temporales, he seleccionado la serie histórica correspondiente a la Extensión del Hielo Marino en el Ártico, disponible en el repositorio oficial del National Snow and Ice Data Center (NSIDC): [Index of /NOAA/G02135/north/monthly/data/](https://nsidc.org/data/NOAA/G02135/north/monthly/data/). Los datos presentan una frecuencia mensual y abarcan un periodo histórico significativo que nos permite analizar la evolución climática a medio y largo plazo, a través de la variable 'extent'. La elección de esta variable no es meramente estadística, sino que responde a la necesidad de modelar uno de los indicadores más críticos del cambio climático global, donde la precisión en la predicción tiene implicaciones directas en estudios ambientales y geopolíticos.

Desde la perspectiva de la modelización estadística, consideramos que este conjunto de datos es idóneo para los objetivos académicos del presente trabajo por la riqueza de sus componentes estructurales:

- **Componente Estacional Definida:** La serie exhibe un comportamiento cíclico anual extremadamente robusto y predecible, dictado por los procesos físicos de congelación (invierno) y deshielo (verano).
- **Tendencia y No Estacionariedad:** A diferencia de series estáticas, esta serie presenta una tendencia decreciente subyacente (hipotéticamente determinista o estocástica) que sugiere que la serie no es estacionaria en media.

El objetivo principal de este estudio será encontrar el modelo matemático que mejor minimice el error de predicción. Compararemos la eficacia de los enfoques de alisado exponencial frente a la familia de modelos autorregresivos integrados (ARIMA), buscando no solo el mejor ajuste histórico, sino la mayor capacidad de generalización para datos futuros.

1.1. Carga de datos

La obtención del conjunto de datos se automatizó mediante un script que interactúa directamente con el repositorio oficial de la NOAA/NSIDC. El proceso de extracción se diseñó para iterar dinámicamente sobre los doce meses del año, realizando peticiones web (vía HTTP) para descargar los registros históricos mensuales. El algoritmo cuenta con un control de versiones que intenta acceder a la versión más reciente de los datos, leyendo el contenido en memoria y limpiando de forma inmediata los encabezados de las columnas para evitar errores de sintaxis provocados por espacios en blanco residuales. Una vez capturada y depurada la información de cada mes, todos los subconjuntos de datos se concatenaron verticalmente, dando lugar a un único conjunto de datos global.

Una vez unificados los registros, se procedió a su estructuración temporal y delimitación. El algoritmo utilizó las columnas originales de año y mes para generar un nuevo índice temporal continuo (Date), asignando cada medición al primer día de su mes correspondiente y ordenando toda la serie de forma estrictamente cronológica.

Finalmente, se aplicó un proceso de filtrado para conservar exclusivamente el periodo comprendido entre enero de 2010 y diciembre de 2025 (192 datos), y se aisló la variable de interés principal, la extensión del hielo ('extent'). El conjunto resultante fue exportado a un archivo CSV local ("hielo_artico_master.csv"), constituyendo una serie temporal univariante, continua y lista para la fase de modelado predictivo.

```
base_url = "https://noaa.data.apps.noaa.gov/noaa/v3/monthly/data/"

lista_dfs = []
print("Iniciando descarga y fusión de datos...")

# Recorremos los 12 meses
for mes in range(1, 13):
    mes_str = f"{mes:02d}"

    # Probamos primero la v3.0 y si falla, la v4.0
    versiones = ["v3.0", "v4.0"]
    descargado = False

    for version in versiones:
        if descargado: break
        try:
            archivo = f"N_{mes_str}_extent_{version}.csv"
            url = base_url + archivo
            r = requests.get(url, timeout=10)
            if r.status_code == 200:
                df_mes = pd.read_csv(io.StringIO(r.text), skipinitialspace=True)
                # Limpiamos nombres de columnas inmediatamente
                df_mes.columns = df_mes.columns.str.strip()
                lista_dfs.append(df_mes)
                print(f"✅ Mes {mes_str} descargado ({version}).")
                descargado = True
            else:
                continue

        except:
            continue

    if not descargado:
        print(f"❌ No se encontró el mes {mes_str} en ninguna versión.")

# Fusión
if lista_dfs:
    df_total = pd.concat(lista_dfs)

    # Crear fecha y ordenar
    df_total['Date'] = pd.to_datetime(dict(year=df_total['year'], month=df_total['mo'], day=1))
    df_total = df_total.set_index('Date').sort_index()

    # Filtrar rango exacto para el Máster (2010-2025)
    dataset_final = df_total.loc['2010-01-01':'2025-12-31', ['extent']]

    # Guardar CSV localmente
    nombre_archivo = "hielo_artico_master.csv"
    dataset_final.to_csv(nombre_archivo)

    print(f"¡Proceso terminado! Tienes {len(dataset_final)} datos.")
    print(f"📁 Archivo guardado con éxito como: '{nombre_archivo}'")
else:
    print("Error crítico: No se pudieron descargar datos. Comprueba tu conexión a internet.")
```


Tras esto, ya podemos comenzar en análisis cargando el archivo "df = pd.read_csv('hielo_artico_master.csv')". La variable de interés es 'extent' que representa la extensión del hielo. Vamos a convertir la columna de fecha al formato adecuado y establecerla como índice, para seguidamente visualizar gráficamente nuestra serie.

```
df = pd.read_csv('hielo_artico_master.csv')

df['Date'] = pd.to_datetime(df['Date'])
df.set_index('Date', inplace=True)

# Asignamos frecuencia mensual (Month Start)
df.index.freq = 'MS'

# Representación gráfica inicial
plt.figure(figsize=(12, 6))
plt.plot(df.index, df['extent'], label='Extensión Hielo Ártico')
plt.title('Evolución de la Extensión del Hielo Ártico')
plt.xlabel('Fecha')
plt.ylabel('Extensión')
plt.legend()
plt.show()
```



A primera vista, observamos una clara estacionalidad anual: el hielo crece en invierno y disminuye en verano. También parece haber una ligera tendencia decreciente a lo largo de los años, lo cual es consistente con el calentamiento global.

2. Representación gráfica y descomposición estacional


Vamos a descomponer la serie en sus componentes: Tendencia, Estacionalidad y Residuo. Dado que la amplitud de las oscilaciones estacionales parece mantenerse constante (no crece con el tiempo), utilizaremos un modelo aditivo. $Y_t = T_t + S_t + E_t$

Desglose de los componentes:

- Y_t (Serie Observada): El valor real de la variable en el momento t .
- T_t (Tendencia): El movimiento de larga duración o la dirección general de la serie (si sube, baja o se mantiene estable).
- S_t (Estacionalidad): Los patrones que se repiten en intervalos regulares (e.g. las ventas altas en Navidad cada año).
- E_t o R_t (Residuo/Error): La parte aleatoria o irregular que no puede ser explicada por la tendencia ni por la estacionalidad.

```
# Descomposición estacional (Modelo Aditivo)
decomposition = seasonal_decompose(df['extent'], model='additive')

# Gráfico de la descomposición
fig = decomposition.plot()
fig.set_size_inches(12, 10)
plt.suptitle('Descomposición Estacional (Aditiva)', fontsize=16)
plt.tight_layout()
plt.show()
```



En la primera representación gráfica de la serie temporal (Figura 1), donde observamos la evolución de la extensión del hielo ártico desde 2010 hasta la actualidad, destaca de manera inmediata un patrón estacional extremadamente robusto. La serie dibuja una forma de "dientes de sierra" perfecta, con máximos recurrentes en los meses de invierno y mínimos profundos en verano. A simple vista, la amplitud de estas oscilaciones es constante, lo que sugiere un esquema estacional de tipo aditivo o levemente multiplicativo. Sin embargo, más allá de la oscilación anual, se aprecia visualmente una ligera pendiente negativa en los picos y valles a lo largo de la década, indicio preliminar de la tendencia decreciente asociada al calentamiento global.

Para aislar los componentes subyacentes, hemos procedido a una descomposición estacional clásica. Los gráficos resultantes nos ofrecen los siguientes insights:

- **Tendencia (Trend):** Al filtrar el ruido y la estacionalidad, la componente de tendencia confirma nuestra hipótesis visual: existe una tendencia descendente a lo largo del tiempo (patrón estacional muy marcado). Aunque no es una caída lineal perfecta (presenta periodos de estabilización entre 2013-2015), la dirección general es negativa, lo que confirma la pérdida progresiva de masa de hielo a largo plazo.
- **Estacionalidad (Seasonal):** El gráfico del componente estacional muestra un patrón determinista que se repite cada 12 meses ($s=12$). La regularidad es tal que explica la mayor parte de la varianza de la serie original.

- Residuo (Resid): El componente residual (lo que queda tras restar la tendencia y la estacionalidad) muestra fluctuaciones constantes alrededor del cero, lo que a nivel general valida el proceso de descomposición. Sin embargo, es fundamental detenerse en los picos anómalos que aparecen en el gráfico, como el detectado en 2012; este pico negativo no es un error del modelo, sino el reflejo de una anomalía real en el mínimo histórico de hielo ártico provocado por condiciones meteorológicas extremas ese verano. Al observar que el resto de los residuos se comportan de forma mayoritariamente aleatoria ('ruido blanco'), confirmamos que la descomposición ha sido exitosa y que el modelo ha capturado la estructura principal de la serie, aislando correctamente estos eventos excepcionales.

Ahora pasamos a analizar la Tabla de Coeficientes de Estacionalidad. Como es una serie mensual, los coeficientes se repiten cada 12 meses. Mostramos un ciclo completo:

```
seasonal_coeffs = decomposition.seasonal.head(12)
seasonal_df = pd.DataFrame(seasonal_coeffs)
seasonal_df.columns = ['Coeficiente Estacional']
seasonal_df.index.name = 'Mes'
# Extraemos el nombre del mes para mejor interpretación
seasonal_df['Nombre Mes'] = seasonal_df.index.month_name()

print("\nTabla de Coeficientes de Estacionalidad (para un año tipo):")
print(seasonal_df[['Nombre Mes', 'Coeficiente Estacional']])
```

Tabla de Coeficientes de Estacionalidad (para un año tipo):
Nombre Mes Coeficiente Estacional

Mes		
2010-01-01	January	3.046380
2010-02-01	February	3.880852
2010-03-01	March	4.119185
2010-04-01	April	3.448019
2010-05-01	May	2.119519
2010-06-01	June	0.318880
2010-07-01	July	-2.555231
2010-08-01	August	-4.983843
2010-09-01	September	-5.879370
2010-10-01	October	-4.026898
2010-11-01	November	-0.921537
2010-12-01	December	1.434046

El análisis de los coeficientes estacionales nos permite identificar cuatro fases climáticas diferenciadas que rigen el comportamiento anual de la serie:

- Fase de Acumulación (Enero - Abril): Presentan coeficientes positivos, indicando niveles de hielo superiores a la media de la tendencia. Marzo destaca como el máximo estacional (+4.12), coincidiendo con el final del invierno ártico.
- Transición al Deshielo (Mayo - Julio): Se observa una caída drástica en los coeficientes, cruzando el umbral de cero. Es el periodo de derretimiento acelerado.
- Mínimo Estival (Agosto - Octubre): Coeficientes fuertemente negativos. Septiembre registra el valor mínimo absoluto (-5.88), señalando el momento de mayor retroceso de la capa de hielo.
- Recongelación (Noviembre - Diciembre): Recuperación rápida de la extensión, donde los coeficientes vuelven a ser positivos, cerrando el ciclo anual.

3. División en TRAIN y TEST

Para validar nuestros modelos, reservaremos los últimos datos observados. Al ser una serie estacional mensual, reservaremos un ciclo completo, es decir, 12 meses.


TRAIN: Datos para ajustar los modelos. Recoge los datos de extensión del hielo desde 2010 hasta 2024 incluido.

TEST: Últimos 12 meses para comprobar las predicciones, es decir, los datos pertenecientes a 2025.

```
1 test_size = 12
2 train = df['extent'].iloc[:-test_size]
3 test = df['extent'].iloc[-test_size:]
4
5 print(f"Tamaño total: {len(df)}")
6 print(f"Tamaño TRAIN: {len(train)}")
7 print(f"Tamaño TEST: {len(test)}")
8 print(f"\nFecha inicio TEST: {test.index[0]}")
9 print(f"Fecha fin TEST: {test.index[-1]}")
10
11 plt.figure(figsize=(12, 6))
12 plt.plot(train.index, train, label='TRAIN')
13 plt.plot(test.index, test, label='TEST', color='orange')
14 plt.title('División Train/Test')
15 plt.legend()
16 plt.show()
```

Tamaño total: 192
Tamaño TRAIN: 180
Tamaño TEST: 12

Fecha inicio TEST: 2025-01-01 00:00:00
Fecha fin TEST: 2025-12-01 00:00:00



Como se indica en el primer apartado, el dataset recoge un total de 192 datos correspondientes al periodo entre enero de 2010 y diciembre de 2025. De estos registros disponibles, se reservan los últimos 12 para TEST (correspondientes a los meses del año 2025), mientras que los 180 registros restantes se utilizan como conjunto de TRAIN para el entrenamiento del modelo.

4. Modelo de Suavizado Exponencial (Holt-Winters)

Probaremos varios modelos de suavizado exponencial para encontrar el que tenga el menor criterio de información (AIC). El objetivo es encontrar el equilibrio entre la bondad de ajuste y la complejidad del modelo (penalización por número de parámetros). Consideraremos las componentes de Tendencia y Estacionalidad. Modelos para probar:

- Tendencia Aditiva, Estacionalidad Aditiva (AAA)
- Tendencia Aditiva, Estacionalidad Multiplicativa (AAM)
- Tendencia Aditiva Amortiguada, Estacionalidad Aditiva (DAA)

Dado que tenemos ceros o valores negativos en los residuos, el modelo multiplicativo puede dar problemas, pero la serie 'extent' es positiva, así que probaremos.

```
1 # --- PRUEBA DE HIPÓTESIS: Ajuste manual de 3 modelos ---
2
3 # Modelo 1: AAA (Tendencia Aditiva, Estacionalidad Aditiva)
4 modelo_aaa = ExponentialSmoothing(
5     train,
6     seasonal_periods=12,
7     trend="add",
8     seasonal="add",
9     initialization_method="estimated"
10 ).fit()
11
12 # Modelo 2: AAM (Tendencia Aditiva, Estacionalidad Multiplicativa)
13 modelo_aam = ExponentialSmoothing(
14     train,
15     seasonal_periods=12,
16     trend="add",
17     seasonal="mul",
18     initialization_method="estimated"
19 ).fit()
20
21 # Modelo 3: DAA (Tendencia Aditiva Amortiguada, Estacionalidad Aditiva)
22 modelo_daa = ExponentialSmoothing(
23     train,
24     seasonal_periods=12,
25     trend="add",
26     seasonal="add",
27     damped_trend=True,
28     initialization_method="estimated"
29 ).fit()
30
31 # --- COMPARACIÓN DE CRITERIOS (AIC) ---
32 print("--- Comparativa de Modelos (Criterio AIC) ---")
33 print(f"AIC Modelo AAA (Aditivo-Aditivo): {modelo_aaa.aic:.2f}")
34 print(f"AIC Modelo AAM (Aditivo-Multiplicativo): {modelo_aam.aic:.2f}")
35 print(f"AIC Modelo DAA (Amortiguado-Aditivo): {modelo_daa.aic:.2f}\n")
36
37 --- Comparativa de Modelos (Criterio AIC) ---
38 AIC Modelo AAA (Aditivo-Aditivo): -473.68
39 AIC Modelo AAM (Aditivo-Multiplicativo): -415.41
40 AIC Modelo DAA (Amortiguado-Aditivo): -471.67
```

Seleccionamos el modelo Aditivo-Aditivo (Tendencia Aditiva, Estacionalidad Aditiva: AIC -473.67) como el óptimo, descartando las variantes multiplicativa y amortiguada. Esta elección es coherente con la inspección visual, confirmando que la amplitud de la oscilación estacional se mantiene constante e independiente del nivel de la serie.

```

1 # --- SELECCIÓN DEL MODELO GANADOR ---
2 modelo_hw_final = modelo_aaa
3
4 # Extraer y mostrar los parámetros estadísticos del modelo ganador
5 headers = ['Name', 'Param', 'Value', 'Optimized']
6 table_str = tabulate(modelo_hw_final.params_formatted, headers, tablefmt='fancy_grid')
7 print("Parámetros del modelo Holt-Winters ganador:")
8 print(table_str)

```

Parámetros del modelo Holt-Winters ganador:


Name	Param	Value	Optimized
smoothing_level	alpha	0.933702	True
smoothing_trend	beta	0	True
smoothing_seasonal	gamma	0.0662977	True
initial_level	l.0	10.7021	True
initial_trend	b.0	-0.0040968	True
initial_seasons.0	s.0	3.04196	True
initial_seasons.1	s.1	3.85023	True
initial_seasons.2	s.2	4.09648	True
initial_seasons.3	s.3	3.49722	True
initial_seasons.4	s.4	2.14874	True
initial_seasons.5	s.5	0.293921	True
initial_seasons.6	s.6	-2.57586	True
initial_seasons.7	s.7	-4.99008	True
initial_seasons.8	s.8	-5.94399	True
initial_seasons.9	s.9	-4.00719	True
initial_seasons.10	s.10	-0.906099	True
initial_seasons.11	s.11	1.45764	True

El análisis de los parámetros estimados revela un alpha elevado (0.934), lo que indica que el modelo prioriza la información más reciente para actualizar el nivel de la serie. Por el contrario, el beta obtenido es nulo (0.000), lo que sugiere que la tendencia de la serie es sumamente estable y no requiere ajustes locales basados en las últimas observaciones. En la misma línea, el gamma bajo (0.066) confirma que el patrón estacional es estructuralmente muy firme, repitiéndose de manera casi idéntica año tras año sin presentar variaciones significativas en sus ciclos.

```

1 # Mostramos el final de train (últimos 24 meses) para ver la continuidad
2 plt.plot(train.index[-24:], train.iloc[-24:], label='Observado (Train)', color='gray')
3 plt.plot(test.index, test, label='Observado (Test)', color='green')
4
5 # Dibujamos Los valores suavizados por el modelo para esos mismos 24 meses
6 plt.plot(modelo_hw_final.fittedvalues.index[-24:], modelo_hw_final.fittedvalues.iloc[-24:],
7          label='Suavizado (Fitted)', color='blue', linestyle='--', alpha=0.7)
8
9 # Dibujamos Las predicciones futuras (periodo test)
10 plt.plot(predictions_ets.index, predictions_ets, label='Predicción ETS', color='red', linestyle='--')
11
12 plt.title('Suavizado Exponencial: Modelo AAA (Aditivo-Aditivo)')
13 plt.xlabel('Fecha')
14 plt.ylabel('Extensión del Hielo')
15 plt.legend()
16 plt.show()

```



La gráfica muestra cómo el modelo captura bien la estacionalidad y se ajusta a los datos de Test, aunque veremos más adelante cómo compara numéricamente con otros métodos. Para finalizar el apartado, mostramos la tabla con las predicciones:

```

1 predictions_ets = modelo_hw_final.forecast(len(test))
2
3 tabla_resultados = pd.DataFrame({
4     'Observado': test,
5     'Predicción ETS': predictions_ets
6 })
7
8 # Cálculo del Error (resta directa, conservando positivos y negativos)
9 tabla_resultados['Error'] = tabla_resultados['Observado'] - tabla_resultados['Predicción ETS']
10
11 print("--- TABLA DE PREDICCIONES Y ERRORES (TEST) ---")
12 print(tabla_resultados)

```

```

--- TABLA DE PREDICCIONES Y ERRORES (TEST) ---

```

	Observado	Predicción ETS	Error
2025-01-01	13.11	13.026457	0.083543
2025-02-01	13.75	13.824465	-0.074465
2025-03-01	14.12	14.051653	0.068347
2025-04-01	13.83	13.388744	0.441256
2025-05-01	12.49	12.104208	0.385792
2025-06-01	10.40	10.252994	0.147006
2025-07-01	7.66	7.373146	0.286854
2025-08-01	5.39	4.929445	0.460555
2025-09-01	4.75	4.024743	0.725257
2025-10-01	6.32	5.849637	0.470363
2025-11-01	8.77	9.035160	-0.265160
2025-12-01	11.22	11.365502	-0.145502


Al validar con el conjunto de test (2025), las predicciones replican fielmente el ciclo anual, mostrando gran precisión en invierno (meses finales y sobre todo iniciales del año) y una ligera desviación en el mínimo de septiembre (error de 0.725), donde el modelo subestimó levemente el deshielo real.

5. Identificación y Ajuste de Modelo ARIMA Manual

Analizamos la estacionariedad y la estructura de autocorrelación para determinar los parámetros (p,d,q) y (P,D,Q)s.

El primer paso consiste en representar gráficamente la serie original. Esto permite apreciar visualmente si la serie es estacionaria en media y varianza o si, por el contrario, presenta componentes de tendencia y estacionalidad que requieran ser tratados.

```
1 # Graficamos la serie original para ver tendencia y estacionalidad
2 plt.figure(figsize=(12, 4))
3 plt.plot(train)
4 plt.title('Serie Original (Train)')
5 plt.show()
```




La serie original presenta oscilaciones periódicas (estacionalidad), lo que indica que la serie es no estacionaria en la media. Como ocurre con las series que aparecen en el mundo real, en su gran mayoría son no estacionarias por mostrar tendencia, estacionalidad u otros efectos evolutivos en el tiempo. Sin embargo, para poder ajustar un modelo ARMA necesitamos que la serie sea estacionaria, es decir, que su media y varianza permanezcan constantes con el tiempo.

Por ello, se realiza el proceso de diferenciación para transformar los datos. Esta técnica consiste en calcular la variación entre períodos para eliminar las componentes no estacionarias en media, permitiendo que el modelo ARMA se ajuste sobre la serie ya transformada, la cual pasa a denominarse formalmente como modelo ARIMA.

```
# Diferenciación
# Dada la tendencia y estacionalidad anual (s=12), probamos primero con una diferencia estacional y luego una regular.
# Generalmente: D=1 (estacional), d=1 (regular) es común en series mensuales con tendencia.

train_diff_12 = train.diff(12).dropna()
plt.figure(figsize=(12, 4))
plt.plot(train_diff_12)
plt.title('Serie con Diferencia Estacional (D=1)')
plt.show()

train_diff_12_1 = train_diff_12.diff(1).dropna()
plt.figure(figsize=(12, 4))
plt.plot(train_diff_12_1)
plt.title('Serie con Diferencia Estacional y Regular (D=1, d=1)')
plt.show()
```



Para tratar este problema se aplica primero una diferenciación estacional de orden 1 ($D = 1$). Esta transformación consiste en restar cada observación con la del mismo periodo del ciclo anterior. En series mensuales, esto implica comparar cada valor con el observado doce meses antes. Matemáticamente se expresa como:

$$\nabla_s X_t = X_t - X_{t-s}$$

Al aplicar esta transformación se elimina gran parte del patrón estacional repetitivo, ya que se comparan directamente los valores de un mismo mes en años consecutivos. Como resultado, en la gráfica desaparece el ciclo anual dominante y se pueden observar con mayor claridad las variaciones del nivel de la serie.


Sin embargo, después de eliminar la estacionalidad todavía se aprecia que la serie presenta movimientos prolongados en el tiempo. Esto indica que la media de la serie todavía no es completamente constante. Por este motivo se aplica una diferenciación regular de primer orden ($d = 1$), que consiste en restar cada observación con la inmediatamente anterior.

Este tipo de transformación se utiliza cuando una serie presenta tendencia o cambios progresivos en su nivel, ya que permite estabilizar la media de la serie. Matemáticamente se expresa como:

$$\nabla X_t = X_t - X_{t-1}$$

Tras aplicar ambas diferenciaciones (estacional y regular), la serie resultante oscila alrededor de un nivel aproximadamente constante y sin tendencia aparente. Este comportamiento indica que la serie se ha aproximado a un proceso estacionario, condición necesaria para poder ajustar correctamente modelos ARIMA.

```
# Correlogramas de la serie doblemente diferenciada
fig, ax = plt.subplots(2, 1, figsize=(12, 8))
plot_acf(train_diff_12_1, ax=ax[0], lags=48)
plot_pacf(train_diff_12_1, ax=ax[1], lags=48)
plt.suptitle('ACF y PACF de la serie con d=1, D=1')
plt.tight_layout()
plt.show()
```



Estas gráficas muestran que, a corto plazo (los primeros puntos a la izquierda), los datos ya se comportan de forma aleatoria y estable dentro de la franja azul. Sin embargo, el pico pronunciado que sobresale hacia abajo exactamente en el punto 12 (el ciclo anual) sugiere que aún queda una "huella" de la estacionalidad original, la cual corregiremos indicándole al modelo que incluya un parámetro de media móvil estacional (SMA de orden 1).

Decisión del modelo manual:

- d=1, D=1: Parece necesario diferenciar estacional y regularmente para estabilizar la media y eliminar la estacionalidad.

- p, q, P, Q: En series mensuales tipo "Airline", es común encontrar un modelo SARIMA(0, 1, 0)(0, 1, 1)₁₂ o SARIMA(0, 1, 1)(0, 1, 1)₁₂. Esto se justifica al observar un pico negativo claro en el rezago estacional (lag 12) del ACF, lo que sugiere un término de media móvil estacional (Q=1), y un comportamiento de ruido blanco en los primeros rezagos, sugiriendo p=0 y q=0.

```
# Ajuste Manual: SARIMA(0, 1, 1)x(0, 1, 1, 12)
manual_order = (0, 1, 1)
manual_seasonal_order = (0, 1, 1, 12)

print(f"Ajustando modelo manual SARIMA{manual_order}x{manual_seasonal_order}...")
model_manual = SARIMAX(train, order=manual_order, seasonal_order=manual_seasonal_order)
results_manual = model_manual.fit(dispatch=False)

print(results_manual.summary())
```

```
Ajustando modelo manual SARIMA(0, 1, 1)x(0, 1, 1, 12)...
SARIMAX Results
```

Dep. Variable:		extent		No. Observations:		180
Model:	SARIMAX(0, 1, 1)x(0, 1, 1, 12)			Log Likelihood		-20.581
Date:	Tue, 17 Feb 2026			AIC		47.163
Time:	19:08:55			BIC		56.517
Sample:	01-01-2010			HQIC		50.959
	- 12-01-2024					
Covariance Type:		opg				
	coef	std err	z	P> z	[0.025	0.975]
ma.L1	-0.0705	0.069	-1.016	0.310	-0.206	0.066
ma.S.L12	-0.7416	0.059	-12.674	0.000	-0.856	-0.627
sigma2	0.0707	0.008	8.902	0.000	0.055	0.086
Ljung-Box (L1) (Q):			0.01	Jarque-Bera (JB):		0.11
Prob(Q):			0.94	Prob(JB):		0.95
Heteroskedasticity (H):			0.67	Skew:		0.03
Prob(H) (two-sided):			0.14	Kurtosis:		3.11

Diagnóstico de residuos: Las pruebas de la parte inferior (Ljung-Box, Jarque-Bera y Heterocedasticidad) tienen p-valores muy altos (superiores a 0.05). Esto indica que el modelo ha capturado toda la información: lo que sobra es ruido blanco, con varianza constante y distribución normal (campana de Gauss perfecta).


Estacionalidad: El término estacional (ma.S.L12) tiene un p-valor de 0.000. Es estadísticamente muy significativo y hace el trabajo pesado del modelo.

Un parámetro innecesario: El término de media móvil a corto plazo (ma.L1) tiene un p-valor de 0.310 (mayor a 0.05). Esto significa que estadísticamente no aporta valor predictivo real y está sobrando.

El modelo es excelente prediciendo y limpiando la señal, pero no cumple con el principio de parsimonia (usar el modelo más simple posible). El resultado te invita directamente a simplificarlo eliminando el parámetro q=1.

```
# Diagnóstico de residuos
results_manual.plot_diagnostics(figsize=(12, 10))
plt.show()

# Test de Ljung-Box para incorrelación de residuos
# Comprobamos si los residuos son ruido blanco (p-value > 0.05)
lb_test = acorr_ljungbox(results_manual.resid, lags=[12, 24], return_df=True)
print("\nTest de Ljung-Box (p-values):")
print(lb_test)
```



```
Test de Ljung-Box (p-values):
   lb_stat  lb_pvalue
12  37.148171  0.000211
24  37.624869  0.037863
```

Standardized residual: Muestra los errores del modelo a lo largo del tiempo. Parece un "ruido" aleatorio: fluctúa alrededor de la línea del cero sin una tendencia evidente y con una amplitud (varianza) bastante constante. No hay patrones obvios.

Histogram plus estimated density: La línea naranja (residuos) calca casi a la perfección la línea verde (la distribución normal teórica). Los errores tienen una forma de campana de Gauss ideal teóricamente hablando.

Normal Q-Q: Confirma lo anterior. Los puntos azules siguen la línea roja diagonal casi perfectamente, salvo mínimas desviaciones en los extremos (lo cual es completamente normal). Los residuos se distribuyen normalmente.

Correlogram: Muestra que en el corto plazo (rezagos del 1 al 10), ningún punto sobresale de la zona azul, salvo el punto 5 de una manera muy ligera. No hay autocorrelación a corto plazo.

Test de Ljung-Box): revela algo que el correlograma ocultaba porque solo llegaba hasta el rezago 10:

- Lag 12 (rezago anual): Tiene un p-valor de 0.000211.
- Lag 24 (rezago bianual): Tiene un p-valor de 0.037863.

Como ambos valores son menores a 0.05, la prueba matemática nos indica de forma estricta que sí queda autocorrelación estacional significativa en los residuos. Aunque el modelo limpió casi todo, dejó un pequeño rastro del patrón anual que no logró capturar del todo con ese único parámetro $Q=1$.

6. Ajuste Automático (Auto ARIMA) y Selección

Utilizamos 'auto_arima' para buscar el modelo óptimo barriendo diferentes combinaciones de parámetros y minimizando el AIC.

```
model_auto = pm.auto_arima(train,
                           seasonal=True, m=12,
                           d=1, D=1,
                           start_p=0, start_q=0,
                           max_p=3, max_q=3, max_P=3, max_Q=3,
                           trace=True,
                           error_action='ignore',
                           suppress_warnings=True,
                           stepwise=True)

print("\nMejor modelo encontrado por Auto ARIMA:")
print(model_auto.summary())
```

Best model: ARIMA(0,1,0)(1,1,1)[12]
Total fit time: 21.234 seconds

Mejor modelo encontrado por Auto ARIMA:

SARIMAX Results						
=====						
Dep. Variable:	y			No. Observations:	180	
Model:	SARIMAX(0, 1, 0)x(1, 1, [1], 12)			Log Likelihood	-18.521	
Date:	Thu, 19 Feb 2026			AIC	43.041	
Time:	21:49:52			BIC	52.395	
Sample:	01-01-2010			HQIC	46.838	
	- 12-01-2024					
Covariance Type:	opg					
=====						
	coef	std err	z	P> z	[0.025	0.975]

ar.S.L12	0.2325	0.113	2.066	0.039	0.012	0.453
ma.S.L12	-0.8765	0.119	-7.364	0.000	-1.110	-0.643
sigma2	0.0678	0.008	8.924	0.000	0.053	0.083
=====						
Ljung-Box (L1) (Q):			0.38	Jarque-Bera (JB):	0.92	
Prob(Q):			0.54	Prob(JB):	0.63	
Heteroskedasticity (H):			0.60	Skew:	0.00	
Prob(H) (two-sided):			0.06	Kurtosis:	3.36	

'auto_arima' ha encontrado como mejor modelo exactamente el que sospechábamos al final del análisis anterior: SARIMA(0, 1, 0)(1, 1, 1)₁₂.

Ha hecho exactamente las dos correcciones que necesitábamos: eliminó el parámetro a corto plazo que no servía ($q=1$) y añadió el término autorregresivo estacional ($P=1$) para limpiar ese rastro anual que quedaba en los residuos.

Mostramos el desglose del modelo ganador definitivo:

- El modelo es matemáticamente superior (AIC más bajo, 43.041): El Criterio de Información de Akaike (AIC) sirve para comparar modelos; cuanto más bajo, mejor. El modelo manual anterior tenía un AIC de 47.163. Esta bajada a 43.041 confirma que este nuevo modelo es estadísticamente superior porque explica mejor los datos usando la combinación óptima de parámetros.
- La columna $P > |z|$ muestra que el nuevo término estacional que se añadió (ar.S.L12), tiene un p-valor de 0.039. Al ser menor de 0.05, nos confirma que incluirlo fue un acierto estadístico.
- El término de media móvil estacional (ma.S.L12) sigue haciendo el trabajo pesado con un p-valor de 0.000.
- Ya no hay parámetros de relleno. El modelo es parsimonioso (lo más simple y eficiente posible).
- Los residuos siguen siendo perfectos: Jarque-Bera (Prob = 0.63) es muy superior a 0.05, lo que certifica que los errores siguen una distribución normal pura. Si nos fijamos en la asimetría, es exactamente 0.00. Una campana de Gauss impecable; Ljung-Box (Prob = 0.54) nos confirma que no hay autocorrelación en el primer rezago (ruido blanco).

```
1 # Comparación de modelos
2 aic_manual = results_manual.aic
3 aic_auto = model_auto.aic()
4
5 print(f"\nAIC Manual: {aic_manual:.4f}")
6 print(f"AIC Auto: {aic_auto:.4f}")
7
8 if aic_auto < aic_manual:
9     best_arima_model = model_auto
10    print("-> El modelo Auto ARIMA es mejor (menor AIC).")
11 else:
12     best_arima_model = results_manual # Nota: Si gana manual, usaremos el objeto results_manual
13    print("-> El modelo Manual es mejor o igual (menor AIC).")
```

```
AIC Manual: 47.1628
AIC Auto: 43.0413
-> El modelo Auto ARIMA es mejor (menor AIC).
```

El código corrobora lo que hemos mencionado anteriormente, el modelo Auto es matemáticamente superior (AIC más bajo) al modelo Manual anterior.

7. Expresión Algebraica del Modelo Óptimo

```
1 if aic_auto < aic_manual:
2     # Ajustamos un SARIMAX con los parametros de auto_arima para tener consistencia en los objetos
3     final_order = model_auto.order
4     final_seasonal_order = model_auto.seasonal_order
5     final_model = SARIMAX(train, order=final_order, seasonal_order=final_seasonal_order).fit(dispatch=False)
6 else:
7     final_order = manual_order
8     final_seasonal_order = manual_seasonal_order
9     final_model = results_manual
10
11 print(f"\nModelo Final Seleccionado: SARIMA{final_order}x{final_seasonal_order}")
12 print("Coeficientes estimados:")
13 print(final_model.params)
14
```

```
Modelo Final Seleccionado: SARIMA(0, 1, 0)x(1, 1, 12)
Coeficientes estimados:
ar.S.L12    0.232451
ma.S.L12   -0.876503
sigma2      0.067799
dtype: float64
```

Tras la evaluación mediante Auto ARIMA, el modelo óptimo seleccionado para la predicción de la extensión del hielo ártico es un SARIMA(0, 1, 0)(1, 1, 1)₁₂. Este modelo captura la estacionalidad anual presente en la serie, característica habitual en variables climáticas como la extensión del hielo marino en el Ártico.

La expresión algebraica general de un modelo estacional, empleando el operador de retardo B (donde $B^k y_t = y_{t-k}$), viene dada por la siguiente formulación:

$$(1 - \phi_1 B - \dots - \phi_p B^p)(1 - \Phi_1 B^{12} - \dots - \Phi_P B^{12P})(1 - B)^d(1 - B^{12})^D y_t = (1 + \theta_1 B + \dots + \theta_q B^q)(1 + \Theta_1 B^{12} + \dots + \Theta_Q B^{12Q}) \epsilon_t$$

Dado que nuestro modelo definitivo no cuenta con parámetros autorregresivos ni de media móvil en su parte regular ($p=0$, $q=0$), pero sí incluye diferenciación regular y estacional ($d=1$, $D=1$), además de un término AR estacional ($P=1$) y un término MA estacional ($Q=1$), la ecuación teórica se simplifica a:

$$(1 - \Phi_1 B^{12})(1 - B)^1(1 - B^{12})^1 y_t = (1 + \Theta_1 B^{12}) \epsilon_t$$

A partir del resumen del ajuste del modelo en Python, hemos obtenido los siguientes estimadores para los hiperparámetros:

- ar.S.L12 (Φ_1) = 0.232451
- ma.S.L12 (Θ_1) = -0.876503

Sustituyendo estos valores exactos en nuestra ecuación simplificada, obtenemos la expresión algebraica final y concreta que rige nuestra serie temporal:

$$(1 - 0.2325 B^{12})(1 - B)(1 - B^{12}) y_t = (1 - 0.8765 B^{12}) \epsilon_t$$

Leyenda de la ecuación:

- y_t : Extensión del hielo ártico en el periodo actual.
- $(1 - 0.2325B^{12})$: Componente autorregresivo estacional que modela la inercia anual.
- $(1 - B)$: Diferencia regular de primer orden que elimina la tendencia local subyacente.
- $(1 - B^{12})$: Diferencia estacional que elimina el fuerte patrón repetitivo anual.
- $(1 - 0.8765B^{12})$: Componente de media móvil estacional, que corrige los impactos de los shocks o errores pasados en el mismo mes del año anterior.
- ϵ_t : Término de error aleatorio (ruido blanco) con media cero y varianza constante.

8. Predicciones e Intervalos de Confianza

Tras ajustar y validar nuestro modelo definitivo SARIMA(0, 1, 0)(1, 1, 1)₁₂, procedemos a evaluar su rendimiento sobre el conjunto de test correspondiente al año 2025.


```
1 # Predicción sobre el conjunto de test (12 meses)
2 forecast_object = final_model.get_prediction(start=test.index[0], end=test.index[-1])
3 predictions_arima = forecast_object.predicted_mean
4 conf_int_arima = forecast_object.conf_int(alpha=0.05) # 95% confianza (alpha=0.05)
5
6 print("\nTabla de Predicciones ARIMA y Test:")
7 pred_table_arima = pd.DataFrame({
8     'Observado': test,
9     'Predicción ARIMA': predictions_arima,
10    'IC Inferior': conf_int_arima.iloc[:, 0],
11    'IC Superior': conf_int_arima.iloc[:, 1]
12 })
13 print(pred_table_arima)
14
```

Tabla de Predicciones ARIMA y Test:				
	Observado	Predicción ARIMA	IC Inferior	IC Superior
2025-01-01	13.11	13.128771	12.617150	13.640393
2025-02-01	13.75	13.923061	13.199732	14.646389
2025-03-01	14.12	14.158292	13.272486	15.044098
2025-04-01	13.83	13.413581	12.390791	14.436372
2025-05-01	12.49	12.106797	10.963317	13.250278
2025-06-01	10.40	10.268200	9.015605	11.520796
2025-07-01	7.66	7.377001	6.024062	8.729940
2025-08-01	5.39	4.848475	3.402138	6.294812
2025-09-01	4.75	3.978542	2.444483	5.512602
2025-10-01	6.32	5.712942	4.095912	7.329973
2025-11-01	8.77	8.881283	7.185337	10.577230
2025-12-01	11.22	11.201746	9.430395	12.973096

```

1 plt.figure(figsize=(12, 6))
2 # Mostramos últimos 2 años de train para contexto
3 plt.plot(train.index[-24:], train.iloc[-24:], label='Observado (Train)')
4 plt.plot(test.index, test, label='Observado (Test)', color='green', linewidth=2)
5 # Predicción ARIMA
6 plt.plot(predictions_arima.index, predictions_arima, label='Predicción ARIMA', color='red', linestyle='--', linewidth=2)
7 # Intervalo de confianza
8 plt.fill_between(predictions_arima.index,
9                  conf_int_arima.iloc[:, 0],
10                 conf_int_arima.iloc[:, 1],
11                 color='red', alpha=0.1, label='IC 95%')
12
13 plt.title(f'Predicción ARIMA {final_order}x{final_seasonal_order} vs Realidad')
14 plt.xlabel('Fecha')
15 plt.ylabel('Extensión')
16 plt.legend()
17 plt.show()

```



Al observar la gráfica de pronóstico y la tabla de resultados, la conclusión principal es que el modelo generaliza de manera excepcional. Logra capturar con gran precisión tanto la estructura temporal como la fuerte dinámica estacional de la serie original, y lo más importante, sin presentar indicios de *overfitting* a los datos de entrenamiento.

Si analizamos las predicciones puntuales frente a los valores reales observados, la exactitud es sumamente destacable. La trayectoria proyectada (la línea punteada) calca prácticamente el comportamiento real de los datos a lo largo de todo el año evaluado. Observando la tabla adjunta, en meses como enero y diciembre de 2025, la diferencia entre nuestra predicción y el valor real es de apenas unas centésimas (13.12 frente a 13.11, y 11.20 frente a 11.22, respectivamente). El modelo acierta de lleno en los puntos de inflexión, replicando correctamente tanto el pico de máxima extensión entre febrero y marzo, como la caída profunda de septiembre, manteniendo intacta la amplitud del ciclo.

Por otro lado, la evaluación de los intervalos de confianza al 95% confirma la robustez estadística de nuestro ajuste. A lo largo de los 12 meses del horizonte de predicción, la totalidad de las observaciones reales se mantienen dentro de los límites superior e inferior estimados por el modelo. Incluso en septiembre, donde registramos la mayor divergencia puntual (una estimación de 3.97 frente a un valor real de 4.75), la observación cae dentro del rango probabilístico. Además, podemos notar visualmente cómo este intervalo se

ensancha de forma muy sutil a medida que avanzamos hacia finales de 2025, un comportamiento lógico; a medida que nos alejamos del último dato real, la incertidumbre aumenta y el margen de error de la predicción se hace un poco más grande. Esto confirma que el modelo está estimando el riesgo de forma coherente.

9. Comparación de Métodos y Conclusiones

Comparamos el modelo de Suavizado Exponencial (apartado 4) con el modelo ARIMA elegido:

```
# Calculamos métricas de error
rmse_ets = np.sqrt(mean_squared_error(test, predictions_ets))
rmse_arima = np.sqrt(mean_squared_error(test, predictions_arima))

mae_ets = np.mean(np.abs(test - predictions_ets))
mae_arima = np.mean(np.abs(test - predictions_arima))

print(f"RMSE Suavizado Exponencial: {rmse_ets:.4f}")
print(f"RMSE Modelo ARIMA: {rmse_arima:.4f}")
print("-" * 40)
print(f"MAE Suavizado Exponencial: {mae_ets:.4f}")
print(f"MAE Modelo ARIMA: {mae_arima:.4f}")

# Tabla comparativa final
comparison_df = pd.DataFrame({
    'Fecha': test.index,
    'Real': test.values,
    'Pred_ETS': predictions_ets.values,
    'Pred_ARIMA': predictions_arima.values,
    'AbsErr_ETS': np.abs(test.values - predictions_ets.values),
    'AbsErr_ARIMA': np.abs(test.values - predictions_arima.values)
}).set_index('Fecha')

print("\nDetalle de errores por mes:")
print(comparison_df)
```

```
RMSE Suavizado Exponencial: 0.3554
RMSE Modelo ARIMA: 0.3785
```

```
-----
MAE Suavizado Exponencial: 0.2962
MAE Modelo ARIMA: 0.2912
```


Detalle de errores por mes:

	Real	Pred_ETS	Pred_ARIMA	AbsErr_ETS	AbsErr_ARIMA
Fecha					
2025-01-01	13.11	13.026457	13.128771	0.083543	0.018771
2025-02-01	13.75	13.824465	13.923061	0.074465	0.173061
2025-03-01	14.12	14.051653	14.158292	0.068347	0.038292
2025-04-01	13.83	13.388744	13.413581	0.441256	0.416419
2025-05-01	12.49	12.104208	12.106797	0.385792	0.383203
2025-06-01	10.40	10.252994	10.268200	0.147006	0.131800
2025-07-01	7.66	7.373146	7.377001	0.286854	0.282999
2025-08-01	5.39	4.929445	4.848475	0.460555	0.541525
2025-09-01	4.75	4.024743	3.978542	0.725257	0.771458
2025-10-01	6.32	5.849637	5.712942	0.470363	0.607058
2025-11-01	8.77	9.035160	8.881283	0.265160	0.111283
2025-12-01	11.22	11.365502	11.201746	0.145502	0.018254

```

1 plt.figure(figsize=(12, 6))
2 plt.plot(test.index, test, label='Observado (Test)', color='green', linewidth=2, marker='o')
3 plt.plot(predictions_ets.index, predictions_ets, label=f'ETS (RMSE={rmse_ets:.3f})', color='blue', linestyle='--')
4 plt.plot(predictions_arima.index, predictions_arima, label=f'ARIMA (RMSE={rmse_arima:.3f})', color='red', linestyle='--')
5
6 plt.title('Comparativa Final: ETS vs ARIMA vs Observado')
7 plt.xlabel('Fecha')
8 plt.ylabel('Extensión')
9 plt.legend()
10 plt.grid(True, alpha=0.3)
11 plt.show()

```



A modo de conclusión para nuestro análisis comparativo, hemos enfrentado nuestro modelo ARIMA (SARIMA optimizado) contra un enfoque de Suavizado Exponencial (ETS) sobre el conjunto de test (2025). Al evaluar el rendimiento general, la primera gran observación es que ambos algoritmos presentan una capacidad predictiva excepcional. Visualmente, tanto la curva roja del ARIMA como la curva azul del ETS siguen muy de cerca la trayectoria real (línea verde), capturando a la perfección la fuerte estacionalidad y los puntos de inflexión de la serie. Esto confirma que ambas aproximaciones matemáticas lograron entender el fenómeno sin caer en el *overfitting*.

Adentrándonos en las métricas de evaluación, encontramos un escenario estadístico donde cada modelo destaca según el criterio que miremos. Por un lado, el modelo ETS logra un RMSE ligeramente inferior (0.3554 frente a 0.3785 del ARIMA). Dado que la métrica RMSE eleva los errores al cuadrado y penaliza fuertemente las grandes desviaciones, esto nos indica que el ETS fue más conservador en los peores meses. Si analizamos esto con la tabla de detalle, comprobamos que en el valle más profundo de la serie (agosto, septiembre y octubre), el ETS logró adaptarse un poco mejor a la caída real, evitando acumular el error absoluto de 0.77 que sí tuvo el ARIMA en septiembre.

Sin embargo, la perspectiva cambia al analizar el Error Absoluto Medio (MAE). En este caso, el modelo ARIMA obtiene un MAE de 0.2912, ligeramente inferior al 0.2962 del modelo ETS. Esto indica que, en promedio, las predicciones del ARIMA presentan un error absoluto algo menor a lo largo del año. La tabla de resultados muestra que ARIMA ofrece mejores estimaciones en algunos meses clave del ciclo anual, como enero, marzo,

noviembre y diciembre. En diciembre, por ejemplo, la diferencia entre el valor real y el estimado es de solo 0.018, lo que refleja un ajuste muy cercano a los datos observados.

En definitiva, la decisión final sobre qué modelo implementar dependerá del objetivo específico de nuestro estudio sobre la extensión del hielo ártico. Si el propósito principal es evitar grandes márgenes de error en meses históricamente críticos (e.g. prever rutas de navegación estival o anticipar el mínimo anual de la capa de hielo en septiembre, priorizando así el RMSE), el modelo ETS se perfila como la opción más robusta debido a su comportamiento conservador en los valles. Por el contrario, si nuestra investigación busca modelar la dinámica general y minimizar la desviación promedio a lo largo de todo el ciclo de congelación y deshielo (priorizando el MAE), el modelo ARIMA que hemos desarrollado resulta el ganador.